

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA TOÁN – TIN HỌC



BÁO CÁO ĐỒ ÁN CUỐI KỲ HỌC PHẦN MÔ HÌNH BAYES

Đề tài: Nghiên cứu mô hình Chiếm cứ (Occupancy Model) theo hướng tiếp cận Bayes và áp dụng cho dữ liệu thực tế

Ngành: Toán học

Chuyên ngành: Xác suất - Thống kê

Giảng viên hướng dẫn: TS. Tô Đức Khánh

Sinh viên: Nguyễn Nhật Huy **MSSV:** 23110020

Thành phố Hồ Chí Minh, Ngày 5 tháng 2 năm 2026

Mục lục

Lời nói đầu	3
1 Tổng quan về bài toán chiếm cứ	5
1.1 Kiến thức chuẩn bị	5
1.2 Câu chuyện về "Âm tính giả"	6
1.3 Mục tiêu và cách tiếp cận của Mô hình chiếm cứ	7
2 Xây dựng Mô hình Toán học	9
2.1 Mô hình chiếm cứ đơn giản	9
2.2 Mô hình chiếm cứ tổng quát	16
2.3 Mô hình chiếm cứ Probit	27
2.4 Một vài khái niệm mở rộng	35
3 Ứng dụng thực tế mô hình trên dữ liệu chuẩn Vịt cổ xanh Bắc Mỹ	37
4 Tổng kết	45
Tài liệu tham khảo	45

Lời nói đầu

Mô hình chiếm cứ (Occupancy Model) là một phương pháp thống kê sinh thái học dùng để đánh giá sự hiện diện thực sự của một loài tại một khu vực (xác suất có mặt) khi đối mặt với khả năng phát hiện không hoàn hảo (không phải lúc nào cũng thấy được loài dù chúng có ở đó), giúp ước tính phân bố và trạng thái loài chính xác hơn theo thời gian. Nó phân biệt giữa xác suất một loài có mặt và xác suất phát hiện nó, cho phép các nhà khoa học hiểu rõ hơn về phân bố và sự thay đổi của loài mà không bị nhiễu bởi việc bỏ sót dữ liệu quan sát.

Với đề tài "**Nghiên cứu mô hình Chiếm cứ (Occupancy Model) theo hướng tiếp cận Bayes và áp dụng cho dữ liệu thực tế**", đề án không chỉ dừng lại ở việc hệ thống hóa cơ sở lý thuyết mà còn trực tiếp xây dựng thuật toán trên ngôn ngữ lập trình R và kiểm chứng trên bộ dữ liệu thực nghiệm về loài Vịt cổ xanh (*Anas platyrhynchos*). Kết quả nghiên cứu được kỳ vọng sẽ làm rõ ưu thế của phương pháp Bayes trong việc xử lý các dữ liệu sinh thái có sai số, đồng thời cung cấp một quy trình phân tích định lượng tin cậy có thể áp dụng rộng rãi trong công tác bảo tồn.

Em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS.Tô Đức Khánh. Thầy đã tận tình hướng dẫn, cung cấp những kiến thức nền tảng quý báu về thống kê Bayes và cách xây dựng mô hình, điều này đã giúp em định hướng tư duy phân tích dữ liệu trong suốt quá trình thực hiện đề án. Dù em đã đọc kỹ và kiểm tra báo cáo lại nhiều lần, tuy nhiên những sai sót là không thể tránh khỏi. Những lời nhận xét và góp ý của Thầy/Cô không chỉ giúp em hoàn thiện đề án này mà còn là hành trang kiến thức quan trọng cho em trên con đường nghiên cứu sau này.

Em xin chân thành cảm ơn!

Chương 1

Tổng quan về bài toán chiếm cứ

1.1 Kiến thức chuẩn bị

1.1.1 Định lý Bayes và Suy diễn thống kê Bayes

Thống kê Bayes dựa trên nguyên lý cập nhật niềm tin về các tham số chưa biết (θ) khi có thêm dữ liệu quan sát (y). Nền tảng của phương pháp này là Định lý Bayes, được biểu diễn qua công thức:

$$P(\theta|y) = \frac{P(y|\theta) \cdot P(\theta)}{P(y)}$$

Trong đó,

- $P(\theta)$ - Phân phối Tiên nghiệm (Prior): Thể hiện thông tin ban đầu về tham số θ trước khi quan sát dữ liệu.
- $P(y|\theta)$ - Hàm khả năng (Likelihood): Xác suất quan sát được dữ liệu y với giả định tham số là θ .
- $P(\theta|y)$ - Phân phối Hậu nghiệm (Posterior): Phân phối xác suất của tham số θ sau khi đã cập nhật thông tin từ dữ liệu y . Đây là mục tiêu cần tìm của suy diễn Bayes.
- $P(y)$ - Bằng chứng (Evidence): Hằng số chuẩn hóa (marginal likelihood), đảm bảo tổng xác suất bằng 1.

Vì $P(y)$ là hằng số không phụ thuộc vào θ , định lý Bayes thường được viết dưới dạng tỷ lệ:

Hậu nghiệm $\propto$ Hàm khả năng $\times$ Tiên nghiệm

$$P(\theta|y) \propto L(y|\theta) \cdot \pi(\theta)$$

1.1.2 Phương pháp Markov Chain Monte Carlo (MCMC)

Trong các mô hình phức tạp (nhiều tham số), việc tính toán trực tiếp phân phối hậu nghiệm $P(\theta|y)$ là bất khả thi do khó khăn trong việc tính tích phân mẫu số $P(y)$. Để giải quyết vấn đề này, phương pháp MCMC được sử dụng để xấp xỉ phân phối hậu nghiệm.

- Monte Carlo: Là kỹ thuật ước lượng các tính chất của một phân phối (như trung bình, phương sai) bằng cách lấy mẫu ngẫu nhiên lặp lại nhiều lần.
- Markov Chain (Chuỗi Markov): Là một chuỗi các biến ngẫu nhiên $\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(t)}$ mà giá trị tương lai chỉ phụ thuộc vào giá trị hiện tại, không phụ thuộc vào quá khứ.

Thuật toán MCMC xây dựng một chuỗi Markov sao cho phân phối dừng (stationary distribution) của nó chính là phân phối hậu nghiệm cần tìm. Sau một số lượng vòng lặp đủ lớn (giai đoạn hội tụ), các mẫu thu được từ chuỗi này có thể được xem là các mẫu ngẫu nhiên từ phân phối hậu nghiệm.

1.1.3 Thuật toán Metropolis-Hastings

Thuật toán Metropolis-Hastings là phương pháp MCMC tổng quát nhất để tạo chuỗi Markov từ một phân phối mục tiêu $P(\theta|y)$ khi không thể lấy mẫu trực tiếp.

Quy trình của thuật toán tại bước lặp t như sau:

- Bước đề xuất (Proposal Step): Từ giá trị hiện tại $\theta^{(t-1)}$, sinh ra một ứng viên mới θ^* dựa trên một phân phối đề xuất (proposal distribution) $q(\theta^*|\theta^{(t-1)})$.
- Bước chấp nhận/từ chối (Accept/Reject Step): Tính xác suất chấp nhận (Acceptance Probability) α :

$$\alpha = \min \left(1, \frac{P(\theta^*|y) \cdot q(\theta^{(t-1)}|\theta^*)}{P(\theta^{(t-1)}|y) \cdot q(\theta^*|\theta^{(t-1)})} \right)$$

Trong đó,

- $\frac{P(\theta^*|y)}{P(\theta^{(t-1)}|y)}$: Là tỷ lệ hàm mật độ hậu nghiệm (posterior ratio). Nếu ứng viên mới θ^* có xác suất hậu nghiệm cao hơn vị trí cũ, tỷ lệ này sẽ > 1 .
- $\frac{q(\theta^{(t-1)}|\theta^*)}{q(\theta^*|\theta^{(t-1)})}$: Là tỷ lệ điều chỉnh của hàm đề xuất (thường bằng 1 nếu hàm đề xuất đối xứng).
- Quyết định:
 - Sinh một số ngẫu nhiên $u \sim \text{Uniform}(0, 1)$.
 - Nếu $u \leq \alpha$: Chấp nhận ứng viên mới ($\theta^{(t)} = \theta^*$).
 - Nếu $u > \alpha$: Bác bỏ ứng viên, giữ nguyên giá trị cũ ($\theta^{(t)} = \theta^{(t-1)}$).

1.1.4 Thuật toán Lấy mẫu Gibbs

Thuật toán Gibbs Sampling (trình bày ở phần sau) thực chất là một trường hợp đặc biệt của Metropolis-Hastings. Trong Gibbs Sampling, phân phối đề xuất chính là các phân phối có điều kiện đầy đủ (full conditional distributions). Về mặt toán học, điều này dẫn đến việc tỷ lệ chấp nhận α luôn bằng 1. Do đó, trong Gibbs Sampling, mọi mẫu sinh ra đều được chấp nhận mà không cần bước kiểm tra $u \leq \alpha$.

1.2 Câu chuyện về "Âm tính giả"

Trong các nghiên cứu thống kê về các bài toán phân loại, dữ liệu thu thập được thường ở dạng nhị phân, biểu thị sự "Có mặt" hoặc "Vắng mặt" của một đối tượng quan tâm. Tuy nhiên, một vấn đề cốt lõi thường bị bỏ qua trong các mô hình thống kê cổ điển là sự bất đối xứng về độ tin cậy của dữ liệu này. Cụ thể, khi ta quan sát thấy một đối tượng (ghi nhận giá trị 1), ta có thể khá chắc chắn rằng đối tượng đó thực sự hiện diện. Ngược lại, khi ta không quan sát thấy đối tượng (ghi nhận giá trị 0), thông tin này còn có nhiều biến số. Một giá trị quan sát bằng 0 có thể xuất phát từ hai nguyên nhân hoàn toàn khác nhau:

- Sự vắng mặt thực sự (True Absence): Đối tượng không tồn tại tại địa điểm hoặc thời điểm đó.
- Sự vắng mặt giả (False Absence / False Negative): Đối tượng có tồn tại, nhưng quy trình quan sát đã thất bại trong việc phát hiện ra nó.

Hiện tượng này được gọi là "Phát hiện không hoàn hảo" (Imperfect Detection). Trong thực tế, xác suất phát hiện (p) hiếm khi đạt tuyệt đối ($p < 1$) do các yếu tố như: điều kiện môi trường, đặc tính ẩn mình của đối tượng, hoặc hạn chế của thiết bị đo lường. Hệ quả của việc bỏ qua sai số phát hiện:

Nếu sử dụng các mô hình hồi quy phân loại tiêu chuẩn (như Hồi quy Logistic) trực tiếp lên dữ liệu quan sát thô, ta đang ngầm giả định rằng "những gì ta không thấy nghĩa là không có". Điều này dẫn đến các ước lượng bị chệch, cụ thể là đánh giá thấp tỷ lệ hiện diện thực tế của đối tượng trong quần thể. Ta không thể tách biệt được đâu là xác suất hiện diện (ψ) và đâu là xác suất phát hiện (p) chỉ từ một con số 0. Do đó, bài toán đặt ra yêu cầu cần thiết phải có thiết kế thu thập dữ liệu lặp và một khung mô hình toán học đủ mạnh để xử lý sai số này.

1.3 Mục tiêu và cách tiếp cận của Mô hình chiếm cứ

Để giải quyết vấn đề "âm tính giả" nêu trên, Mô hình Chiếm cứ đã (Occupancy Models) được phát triển, đóng vai trò là cầu nối để suy diễn trạng thái thực tế từ dữ liệu quan sát không hoàn hảo.

Mục tiêu của mô hình là ước lượng không thiên lệch xác suất chiếm cứ/hiện diện thực sự (ký hiệu là ψ), đồng thời định lượng được xác suất phát hiện (ký hiệu là p) để hiệu chỉnh các sai số trong quá trình thu thập dữ liệu. Cách tiếp cận của mô hình là tách bài toán thành hai quy trình ngẫu nhiên riêng biệt nhưng có liên hệ mật thiết với nhau:

- Quy trình Sinh thái/Tiềm ẩn (Ecological/Latent Process): Đây là quy trình mô tả "Sự thật" (True State). Nó quy định trạng thái thực sự của đối tượng (Có/Không) tại địa điểm nghiên cứu. Trạng thái này được xem là một biến tiềm ẩn (latent variable, ký hiệu z) mà nhà nghiên cứu không thể quan sát trực tiếp.
- Quy trình Quan sát (Observational Process): Đây là quy trình mô tả "Dữ liệu" (Data). Nó quy định mối quan hệ giữa trạng thái thực (z) và dữ liệu ta ghi nhận được (y), thông qua xác suất phát hiện. Đây thực chất là một mô hình sai số đo lường (measurement error model).

Đây chính là nền tảng lý thuyết để triển khai các mô hình toán học chi tiết sẽ được trình bày ở Chương 2.

Chương 2

Xây dựng Mô hình Toán học

Trong chương này, chúng ta sẽ xây dựng cấu trúc toán học chi tiết cho bài toán chiếm cứ. Trước tiên, ta bắt đầu với mô hình cơ bản để làm rõ cơ chế tương tác giữa các biến tiềm ẩn, sau đó mở rộng sang mô hình tổng quát có chứa các biến giải thích và giải pháp tính toán bằng kỹ thuật Probit.

2.1 Mô hình chiếm cứ đơn giản

Giả sử chúng ta thực hiện khảo sát tại n địa điểm, mỗi địa điểm chúng ta sẽ lặp lại J_i lần khảo sát (tương ứng với địa điểm i với $i = 1, \dots, n$). Khi đó, ta sẽ trình bày mô hình chiếm cứ như một mô hình Bernoulli cụ thể ZI có thứ bậc (hierarchically specified zero-inflated Bernoulli). Trước tiên, ta biểu thị một quy trình chiếm cứ cơ bản với biến tiềm ẩn z_i như một quá trình nhị phân, dùng để biểu thị trạng thái thực của địa điểm i , cụ thể:

$$z_i \sim \text{Bern}(\psi_i), \quad z_i \in \{0, 1\}$$

- Nếu $z_i = 1$: Địa điểm i có đối tượng.
- Nếu $z_i = 0$: Địa điểm i không có đối tượng.

Tham số ψ_i đã được giới thiệu và xây dựng ở *Chương 20*, trong việc thiết lập hồi quy nhị phân, cụ thể:

$$\text{logit}(\psi_i) = \mathbf{x}_i' \boldsymbol{\beta}$$

Trong đó,

- $\mathbf{x}_i$: Vector các biến môi trường tại địa điểm i (ví dụ: độ cao, thảm thực vật...).
- $\boldsymbol{\beta}$: Vector các hệ số hồi quy tương ứng.

Tiếp theo, ta sẽ xây dựng một quy trình quan sát dựa trên các dữ liệu y_{ij} , thể hiện cho sự phát hiện đối tượng được biểu thị bằng các số 0 (không phát hiện) và 1 (có phát hiện), với địa điểm $i = 1, \dots, n$ được lặp lại $j = 1, \dots, J_i$ lần. Mô hình dữ liệu thường được sử dụng trong các bài toán chiếm cứ với khả năng phát hiện không hoàn hảo sẽ xử lý dữ liệu (có điều kiện theo quy trình chiếm cứ z_i) dưới dạng một mô hình hỗn hợp (mixture) như sau:

$$y_{ij} = \begin{cases} \text{Bern}(p) & , z_i = 1 \\ 0 & , z_i = 0 \end{cases}$$

với $i = 1, \dots, n$ và $j = 1, \dots, J_i$. Điều này có nghĩa là khi $z_i = 1$ hay Địa điểm i có đối tượng mà ta cần quan sát, thì y_{ij} sẽ tuân theo phân phối Bernoulli với tham số p , ngược lại khi $z_i = 0$ thì chắc chắn dữ liệu sẽ không quan sát được, nên y_{ij} sẽ luôn nhận giá trị 0.

Đồng thời giả định rằng xác suất phát hiện (p) là đồng nhất giữa các địa điểm (tạm thời giả định như vậy). Ngoài ra, với giả định rằng các lần quan sát lặp lại là độc lập có điều kiện, chúng ta có thể

viết lại mô hình dữ liệu chiếm cứ thành dạng như sau:

$$y_i = \begin{cases} \text{Binom}(J_i, p) & , z_i = 1 \\ 0 & , z_i = 0 \end{cases} \quad (2.1.1)$$

Trong đó $y_i = \sum_{j=1}^{J_i} y_{ij}$ là tổng số lần phát hiện tại địa điểm i . Như vậy, J_i đại diện cho số lượng các phép thử Bernoulli, chính là các lần khảo sát lặp lại trong dữ liệu chiếm cứ đó. Do đó, mô hình chiếm cứ thực chất là một mô hình hồi quy Nhị thức lạm phát số 0 (ZI-Binomial regression model). Nó tương tự nhưng lại khác biệt so với các mô hình ZI-Poisson và ZI-Nhị thức Âm (Chương 22) ở những điểm quan trọng sau:

- Mô hình chiếm cứ được thiết kế đặc thù để mô phỏng một cơ chế quan sát cụ thể dẫn đến sai số đo lường.
- Các mô hình lạm phát số 0 ở Chương 22 giải thích sự biến thiên của tham số trong thành phần hỗn hợp khi $z_i = 1$, trong khi mô hình chiếm cứ đơn giản nhất ở lại tập trung giải thích sự biến thiên trong quy trình cơ sở z_i .

Tức là khi $z_i = 1$ (có sự tồn tại của đối tượng), các mô hình lạm phát số 0 ở chương 22 sẽ quan tâm đến số lượng của đối tượng, còn mô hình chiếm cứ đơn giản nhất sẽ quan tâm đến sự biến thiên của dữ liệu z_i đó.

Tất nhiên, ta có thể thiết lập mô hình chiếm cứ sao cho sự biến thiên nằm ở p thay vì ψ , nhưng làm vậy chủ yếu chỉ cho ta biết về sự thay đổi của quy trình phát hiện - thứ mà ta thường giả định là tương đồng giữa các địa điểm. Tuy nhiên, các câu hỏi sinh thái thường quan tâm đến sự biến thiên của chính quy trình chiếm cứ (loài vật có ở đó hay không).

Để hoàn thiện mô hình chiếm cứ Bayes, ta sẽ cụ thể hóa một tiên nghiệm cho xác suất phát hiện p và hệ số hồi quy chiếm cứ β như sau:

$$\begin{aligned} p &\sim \text{Beta}(\alpha_p, \beta_p), \\ \beta &\sim \mathcal{N}(\mu_\beta, \Sigma_\beta), \end{aligned}$$

điều này dẫn đến kết quả cho phân phối hậu nghiệm sau

$$[z, p, \beta | y] \propto \left(\prod_{i=1}^n [y_i | p]^{z_i} \mathbf{1}_{\{y_i=0\}}^{1-z_i} [z_i | \beta] \right) [p] [\beta] \quad (2.1.2)$$

Giải thích cho công thức này, ta tách chúng ra như sau:

$$[z, p, \beta | y] \propto \left(\prod_{i=1}^n [y_i | p]^{z_i} \mathbf{1}_{\{y_i=0\}}^{1-z_i} \right) \times \left(\prod_{i=1}^n [z_i | \beta] \right) \times [p] [\beta]$$

Đối với phần $\left(\prod_{i=1}^n [y_i | p]^{z_i} \mathbf{1}_{\{y_i=0\}}^{1-z_i} \right)$,

- Khi $z_i = 1$, dữ liệu sẽ tuân theo phân phối Binominal với xác suất p , nên ta viết $[y_i | p]$
- Khi $z_i = 0$, dữ liệu y_i bắt buộc phải $= 0$ (do không có loài vật ở đó nên không thể phát hiện), nên ta dùng hàm chỉ thị $\mathbf{1}_{\{y_i=0\}}$.

Tiếp theo, vì biến z_i được sinh ra từ quy trình sinh thái Bernoulli(ψ_i), mà ψ_i được tính từ β qua hàm logit. Do đó, ta phải nhân thêm xác suất sinh ra z_i là $[z_i | \beta]$. Cuối cùng, ta nhân với xác suất tiên nghiệm của các tham số gốc (p và β) là $[p] [\beta]$. Từ đó, ta được công thức (2.1.2).

Để xây dựng thuật toán MCMC nhằm khớp mô hình chiếm cứ đơn giản với dữ liệu, chúng ta cần thiết lập các phân phối điều kiện đầy đủ, tương tự như quy trình đã thực hiện cho tất cả các mô hình ở những chương trước. Bắt đầu với quy trình chiếm cứ, giống như các mô hình lạm phát số 0 tại **Chương 22**, chúng ta cố định $z_i = 1$ bất cứ khi nào $y_i > 0$. Như vậy, chúng ta chỉ cần lấy mẫu z_i trong trường hợp $y_i = 0$, bởi lẽ trạng thái chiếm cứ chỉ là ẩn số khi chúng ta chưa từng phát hiện được loài vật tại địa điểm đó. Do đó, phân phối điều kiện đầy đủ cho z_i khi $y_i = 0$ là:

$$[z_i|\cdot] \propto [y_i|p]^{z_i} \mathbf{1}_{y_i=0}^{1-z_i} \psi_i^{z_i} (1 - \psi_i)^{1-z_i} \quad (2.1.3)$$

$$\propto (p^{y_i} (1 - p)^{J_i})^{z_i} \mathbf{1}_{y_i=0}^{1-z_i} \psi_i^{z_i} (1 - \psi_i)^{1-z_i} \quad (2.1.4)$$

$$\propto ((1 - p)^{J_i})^{z_i} \psi_i^{z_i} (1 - \psi_i)^{1-z_i} \quad (2.1.5)$$

$$\propto (\psi_i (1 - p)^{J_i})^{z_i} (1 - \psi_i)^{1-z_i} \quad (2.1.6)$$

với $\text{logit}(\psi_i) = \mathbf{x}_i' \beta$. Như vậy, phân phối có điều kiện đầy đủ trong phương trình (2.1.6) có thể suy ra $[z_i|\cdot] = \text{Bern}(\tilde{\psi}_i)$ với

$$\tilde{\psi}_i = \frac{\psi_i (1 - p)^{J_i}}{\psi_i (1 - p)^{J_i} + (1 - \psi_i)} \quad (2.1.7)$$

Như vậy, chúng ta có thể lấy mẫu z_i cho tất cả các trường hợp $y_i = 0$ bằng cách sử dụng các bước cập nhật Gibbs trong thuật toán MCMC. Phân phối điều kiện đầy đủ cho p cũng là liên hợp (conjugate), bởi vì:

$$[p|\cdot] \propto \left(\prod_{i=1}^n [y_i|p]^{z_i} \right) [p] \quad (2.1.8)$$

$$\propto \left(\prod_{\forall z_i=1}^n [y_i|p] \right) [p] \quad (2.1.9)$$

$$\propto p^{\sum_{\forall z_i=1} y_i + \alpha_p - 1} (1 - p)^{\sum_{\forall z_i=1} (J_i - y_i) + \beta_p - 1} \quad (2.1.10)$$

Điều này dẫn đến một phân phối Beta, trong đó $[p|\cdot] = \text{Beta}(\sum_{\forall z_i=1} y_i + \alpha_p, \sum_{\forall z_i=1} (J_i - y_i) + \beta_p)$, mà chúng ta cũng có thể lấy mẫu bằng bước cập nhật Gibbs trong thuật toán MCMC.

Phân phối điều kiện đầy đủ cho β có dạng tương tự như trong các mô hình lạm phát số 0 ở **Chương 22**:

$$[\beta|\cdot] \propto \left(\prod_{i=1}^n [z_i|\beta] \right) [\beta] \quad (2.1.11)$$

$$\propto \left(\prod_{i=1}^n \psi_i^{z_i} (1 - \psi_i)^{1-z_i} \right) [\beta] \quad (2.1.12)$$

Biểu thức này tỷ lệ thuận với chính phân phối điều kiện đầy đủ cho các hệ số mà chúng ta đã thiết lập ở **Chương 20** đối với hồi quy logistic. Do đó, chúng ta có thể sử dụng thuật toán Metropolis-Hastings (M-H) để lấy mẫu β , cùng với phân phối đề xuất chuẩn đa biến bước ngẫu nhiên (random walk multivariate normal proposal distribution) mà chúng ta đã sử dụng ở **Chương 20**. Điều này dẫn đến tỷ lệ chấp nhận M-H là:

$$mh = \frac{\left(\prod_{i=1}^n [z_i|\beta^{(*)}] \right) [\beta^{(*)}]}{\left(\prod_{i=1}^n [z_i|\beta^{(k-1)}] \right) [\beta^{(k-1)}]} \quad (2.1.13)$$

Trong đó $[z_i|\beta]$ đại diện cho hàm khối xác suất (PMF) Bernoulli.

Từ đó, ta xây dựng một thuật toán MCMC trong R có tên là `occ.simple.mcmc.R` để khớp mô hình chiếm cứ đơn giản với dữ liệu dựa trên các phân phối điều kiện đầy đủ:

```

1  occ.simple.mcmc <- function(y,J,X,n.mcmc){
2
3      #####
4      ##### Subroutines
5      #####
6
7      logit.inv <- function(logit){
8
9      exp(logit)/(1+exp(logit))
10     }
11
12     #####
13     ##### Create Variables
14     #####
15
16     n=length(y)
17     pX=dim(X) [2]
18
19     beta.save=matrix(0,pX,n.mcmc)
20     z.mean=rep(0,n)
21     p.save=rep(0,n.mcmc)
22     N.save=rep(0,n.mcmc)
23
24     #####
25     ##### Priors and Starting Values
26     #####
27
28     alpha.p=1
29     beta.p=1
30     beta.mn=rep(0,pX)
31     beta.sd=1.5
32     beta.var=beta.sd^2
33     z=rep(0,n)
34     z[y>0]=1
35     beta=as.vector(glm(z ~ 0+X,family=binomial())
36     $coefficients)
37     beta.tune=1
38
39     #####
40     ##### Begin MCMC Loop
41     #####
42
43     for(k in 1:n.mcmc){
44
45     #####
46     ##### Sample beta
47     #####
48
49         beta.star=rnorm(pX,beta,beta.tune)
50         mh1=sum(dbinom(z,1,logit.inv(X%*%beta.star),

```

```

51     log=TRUE))+sum(dnorm(beta.star,beta.mn,
52     beta.sd,log=TRUE))
53   mh2=sum(dbinom(z,1,logit.inv(X%%beta),
54     log=TRUE))+sum(dnorm(beta,beta.mn,
55     beta.sd,log=TRUE))
56   mh=exp(mh1-mh2)
57   if(mh > runif(1)){
58     beta=beta.star
59   }
60   psi=logit.inv(X%%beta)
61
62   ####
63   #### Sample p
64   ####
65
66   p=rbeta(1,sum(y[z==1])+alpha.p,sum((J-y)[z==1])
67     + beta.p)
68
69   ####
70   #### Sample z
71   ####
72
73   num.tmp = psi*(1-p)^J
74   psi.tmp = num.tmp/(num.tmp+(1-psi))
75   z[y==0] = rbinom(sum(y==0),1,psi.tmp[y==0])
76
77   ####
78   #### Save Samples
79   ####
80   beta.save[,k]=beta
81   p.save[k]=p
82   z.mean=z.mean+z/n.mcmc
83   N.save[k]=sum(z)
84
85 }
86
87   ####
88   #### Write Output
89   ####
90
91   list(beta.save=beta.save,p.save=p.save,N.save
92     =N.save,z.mean=z.mean,n.mcmc=n.mcmc)
93 }

```

Trong đoạn mã R này, chúng ta cũng đã tính toán và lưu lại đại lượng dẫn xuất (derived quantity) $N = \sum_{i=1}^n z_i$, đại diện cho tổng số địa điểm thực sự có loài chiếm cứ. Đại lượng dẫn xuất này cung cấp thêm thông tin suy diễn hữu ích để xác định độ phổ biến của loài trên toàn vùng nghiên cứu.

Ta sẽ áp dụng mô hình chiếm cứ đơn giản này vào dữ liệu của loài chim chích liểu (*Phylloscopus trochilus*), được thu thập tại $n = 37$ địa điểm với chiều cao và mật độ cây liểu (*Salix* spp.) khác nhau ở Finnmark, Na Uy, qua $J = 3$ đợt lấy mẫu lặp lại (theo Henden và cộng sự, 2013). Ta sẽ thiết lập mô hình như đã mô tả, với:

- Xác suất phát hiện (p): Giả định là đồng nhất.
- Xác suất chiếm cứ (ψ_i): Giả định là không đồng nhất thay đổi theo 4 biến giải thích đã được chuẩn hóa: diện tích, mật độ bìa rừng, chiều cao cây liễu và mật độ cây liễu.

Sử dụng các siêu tham số $\alpha_p = 1, \beta_p = 1$ (cho p), $\mu_\beta = 0$, và $\Sigma_\beta = \sigma_\beta^2 I$ với $\sigma_\beta^2 = 2.25$ (cho β), ta xây dựng mô hình với dữ liệu chim chích liễu sử dụng $K = 50.000$ vòng lặp MCMC và đoạn mã R như sau:


```

1 full.df=read.delim("PlosOne-DataFinnmark.txt",
2                     header=TRUE,sep="\t")
3 spp.idx=full.df$Species=="Willow Warbler"
4 y=apply(full.df[spp.idx,1:3],1,sum) # 2015 data
5 n=length(y)
6 X=matrix(1,n,5)
7 X[,2]=scale(full.df[spp.idx,"Pland"])
8 X[,3]=scale(full.df[spp.idx,"ed"])
9 X[,4]=scale(full.df[spp.idx,"wheight"])
10 X[,5]=scale(full.df[spp.idx,"wpf"])
11
12 source("occ.simple.mcmc.R")
13 n.mcmc=50000
14 set.seed(1)
15 mcmc.out=occ.simple.mcmc(y=y,J=3,X=X,n.mcmc=n.mcmc)
16
17 layout(matrix(1:6,3,2,byrow=TRUE))
18 hist(mcmc.out$beta.save[1,-(1:1000)],breaks=30,
19      col=8,xlab=bquote(beta[0]),prob=TRUE,main="a")
20 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
21 hist(mcmc.out$beta.save[2,-(1:1000)],breaks=30,
22      col=8,xlab=bquote(beta[1]),prob=TRUE,main="b")
23 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
24 hist(mcmc.out$beta.save[3,-(1:1000)],breaks=30,
25      col=8,xlab=bquote(beta[2]),prob=TRUE,main="c")
26 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
27 hist(mcmc.out$beta.save[4,-(1:1000)],breaks=30,
28      col=8,xlab=bquote(beta[3]),prob=TRUE,main="d")
29 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
30 hist(mcmc.out$beta.save[5,-(1:1000)],breaks=30,
31      col=8,xlab=bquote(beta[4]),prob=TRUE,main="e")
32 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
33 hist(mcmc.out$p.save[-(1:1000)],breaks=30,col=8,
34      xlab="p",xlim=c(0,1),prob=TRUE,main="f")
35 curve(dunif(x),lwd=2,add=TRUE)
36
37 mean(mcmc.out$p.save[-(1:1000)])
38 quantile(mcmc.out$p.save[-(1:1000)],c(0.025,0.975))

```

Đoạn mã R này mang lại kết quả là các phân phối hậu nghiệm biên (marginal posterior distributions) cho β và p , được hiển thị trong Hình 1. Những kết quả này chỉ ra rằng chúng ta không có đủ dữ liệu để kết luận (infer) rằng mật độ bìa rừng (edge density) hay mật độ cây liễu (willow density) có ảnh

hưởng đến sự chiếm cứ của loài chim chích liểu trong nghiên cứu này. Nguyên nhân là do các phân phối hậu nghiệm biên của chúng bao trùm giá trị 0 một cách đáng kể.



Hình 1. Các phân phối hậu nghiệm biên cho (a) β_0 (hệ số chặn - intercept), (b) β_1 (diện tích), (c) β_2 (mật độ bìa rừng), (d) β_3 (chiều cao cây liểu), (e) β_4 (mật độ cây liểu), và (f) xác suất phát hiện p . Kết quả này thu được từ việc khớp mô hình chiếm cứ đơn giản với dữ liệu chim chích liểu. Các hàm mật độ xác suất tiên nghiệm (Prior PDFs) được hiển thị bằng các đường màu đen để so sánh.

Kết quả từ **Hình 1f** chỉ ra rằng chúng ta có xác suất ở mức trung bình để phát hiện chim chích liểu khi chúng thực sự có mặt tại một địa điểm (Kỳ vọng hậu nghiệm $E(p|y) = 0.57$ và khoảng tin cậy 95% là $[0.42, 0.71]$). Hơn nữa, chúng ta có thể tính toán năng lực phát hiện (power to detect) loài

tại một địa điểm nhất định sau J lần lấy mẫu như sau:

$$P(y > 0 | z = 1) = 1 - P(y = 0 | z = 1) \quad (2.1.14)$$

$$= 1 - \binom{J}{0} p^0 (1-p)^{J-0} \quad (2.1.15)$$

$$= 1 - (1-p)^J \quad (2.1.16)$$

Xác suất này phụ thuộc vào tham số khả năng phát hiện p và số lần lấy mẫu J . Do đó, đây là một đại lượng dẫn xuất (derived quantity) và chúng ta có thể thực hiện suy diễn trên nó để hiểu rõ hơn về hiệu quả lấy mẫu, độ chính xác của quan sát viên/thiết bị, và/hoặc để thiết kế các nỗ lực giám sát chiếm cứ trong tương lai. Trong R, chúng ta có thể tính trung bình hậu nghiệm và khoảng tin cậy 95% cho năng lực phát hiện trong $J = 3$ lần lấy mẫu như sau:

```
1 > pow.detect=1-(1-mcmc.out$p.save[-(1:1000)])^3
2 > mean(pow.detect)
3 [1] 0.9126949
4 > quantile(pow.detect, c(0.025,0.975))
5      2.5%      97.5%
6 0.8059223 0.9751733
```

Vì vậy, kết quả mô hình cho thấy có 91% khả năng phát hiện chim chích liểu tại một địa điểm trong $J = 3$ lần khảo sát nếu nó thực sự có mặt (khoảng tin cậy 95%: [0.81, 0.98]).

Kết quả mô hình làm nổi bật tầm quan trọng của thiết kế khảo sát lặp (replicate sampling). Mặc dù xác suất phát hiện trong một lần viếng thăm đơn lẻ chỉ ở mức trung bình ($p \approx 0.57$), nhưng việc thực hiện $J = 3$ lần lặp lại đã giúp nâng xác suất phát hiện tích lũy lên mức rất cao là 91% (KTC 95%: [0.81, 0.98]).

Điều này cho thấy sai số âm tính giả (False Negative) đã được kiểm soát tốt. Chúng ta có thể tự tin rằng tại những địa điểm mà mô hình báo cáo là 'Vắng mặt' ($y = 0$), khả năng rất cao là loài chim này thực sự không tồn tại ở đó, chứ không phải do chúng ta bỏ sót.

2.2 Mô hình chiếm cứ tổng quát

Sau khi đã thiết lập khung khổ lý thuyết Bayes nền tảng với mô hình đơn giản, trong phần này, chúng ta sẽ mở rộng sang Mô hình chiếm cứ tổng quát. Mô hình này gỡ bỏ giả định về tính đồng nhất, cho phép cả xác suất chiếm cứ (ψ) và xác suất phát hiện (p) biến thiên theo các biến số môi trường thông qua cơ chế hồi quy Logistic (GLM).

Mô hình chiếm cứ đơn giản mà chúng ta đã trình bày ở phần trước đặt ra một giả định khá mạnh, đó là xác suất phát hiện p là đồng nhất trên khắp các địa điểm và các lần khảo sát. Sự mở rộng đơn giản nhất cho mô hình này là cho phép p_i thay đổi theo từng địa điểm, để phản ánh những khác biệt trong đặc điểm nội tại của địa điểm đó hoặc trong cách thức thu thập dữ liệu tại đó. Các ví dụ điển hình cho kiểu biến thiên về khả năng phát hiện này bao gồm: sự thay đổi về mật độ thảm thực vật tầng thấp có thể che khuất nhiều loài động vật nhỏ, hoặc việc sử dụng các quan sát viên khác nhau để thu thập dữ liệu tại các địa điểm khác nhau. Chúng ta chỉ cần thực hiện một điều chỉnh nhỏ đối với mô hình dữ liệu chiếm cứ đơn giản (2.1.1) để cho phép p_i thay đổi phụ thuộc vào các biến giải thích

$$y_i = \begin{cases} \text{Binom}(J_i, p_i) & , z_i = 1 \\ 0 & , z_i = 0 \end{cases} \quad (2.2.1)$$

trong đó $\text{logit}(p_i) = \mathbf{w}_i' \alpha$, một tập hợp các biến giải thích w_i có tiềm năng ảnh hưởng đến khả năng phát hiện tại các địa điểm $i = 1, \dots, n$ cùng các hệ số liên kết α . Tương tự như các hệ số chiếm cứ β , chúng ta có thể sử dụng phân phối tiên nghiệm chuẩn đa biến (multivariate normal prior) cho các hệ số phát hiện α , sao cho $\alpha \sim N(\mu_\alpha, \Sigma_\alpha)$. Phần còn lại của cấu trúc mô hình chiếm cứ đơn giản đã trình bày ở mục trước có thể được tái sử dụng hoàn toàn cho mô hình này, trong đó các biến trạng thái chiếm cứ tiềm ẩn vẫn là $z_i \sim \text{Bern}(\psi_i)$ với $i = 1, \dots, n$, và $\beta \sim N(\mu_\beta, \Sigma_\beta)$.

Như vậy, ta thấy mô hình chiếm cứ tổng quát được thiết lập thông qua hai phương trình hồi quy logistic song song:

Mô hình Quy trình (Process Model):

$$\text{logit}(\psi_i) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} = \mathbf{x}_i' \beta$$

Mô hình Quan sát (Observation Model):

$$\text{logit}(p_i) = \alpha_0 + \alpha_1 w_{i1} + \dots + \alpha_m w_{im} = \mathbf{w}_i' \alpha$$

Trong đó $\mathbf{x}_i$ là các biến môi trường ảnh hưởng đến sự phân bố loài, và $\mathbf{w}_i$ là các biến ảnh hưởng đến khả năng phát hiện.

Phân phối có điều kiện đầy đủ của tham số mới α cũng được xây dựng tương tự như cách chúng ta mô tả ở phần trước cho tham số β , tuy nhiên α sẽ liên quan đến mô hình dữ liệu thay vì mô hình quy trình:

$$[\alpha | \cdot] \propto \left(\prod_{i=1}^n [y_i | \alpha]^{z_i} \right) [\alpha] \quad (2.2.2)$$

$$\propto \left(\prod_{\forall z_i=1}^n [y_i | \alpha] \right) [\alpha] \quad (2.2.3)$$

Trong đó p_i được biết một cách ngầm định khi α và w_i đã biết, bởi vì $\text{logit}(p_i) = w_i \alpha$, và $[y_i | \alpha]$ là hàm khối xác suất (PMF) Nhị thức (Binomial) được tính cho quan sát y_i , với J_i phép thử và xác suất p_i . Nếu chúng ta sử dụng một phân phối đề xuất bước ngẫu nhiên chuẩn tương tự cho α , chúng ta có thể sử dụng tỷ số M-H:

$$mh = \frac{\prod_{\forall z_i=1} [y_i | \alpha^{(*)}] [\alpha^{(*)}]}{\prod_{\forall z_i=1} [y_i | \alpha^{(k-1)}] [\alpha^{(k-1)}]}$$

Phân phối điều kiện đầy đủ cho trạng thái chiếm cứ tiềm ẩn z_i chỉ thay đổi chút ít so với phần trước, cụ thể bây giờ ta có $[z_i | \cdot] = \text{Bern}(\tilde{\psi}_i)$ với:

$$\tilde{\psi}_i = \frac{\psi_i (1 - p_i)^{J_i}}{\psi_i (1 - p_i)^{J_i} + 1 - \psi_i}$$

Phân phối điều kiện đầy đủ cho β giống hệt như phần trước vì nó chỉ phụ thuộc vào z_i (với $i = 1, \dots, n$) và tiên nghiệm của nó.

Với Mô hình chiếm cứ đơn giản, ta thấy rằng p được cập nhật trực tiếp bằng Gibbs Sampling (phân phối Beta). Tuy nhiên, trong Mô hình chiếm cứ tổng quát, ta không đồng nhất xác suất phát hiện p là như nhau ở mọi địa điểm, nên mỗi địa điểm i sẽ có xác suất phát hiện $p_i, i = 1, \dots, n$ khác nhau và phụ thuộc vào hàm $\text{logit}(p_i) = \mathbf{w}_i' \alpha$ nên ta phải dùng Metropolis-Hastings cho α (chứ không dùng Gibbs được nữa). Sự thay đổi của p_i cũng kéo theo sự thay đổi nhỏ của z_i do sự biến thiên của p_i . Tuy nhiên, phần xử lý tham số β vẫn không thay đổi vì nó chỉ phụ thuộc vào z_i và tiên nghiệm của nó.

Sử dụng các phân phối điều kiện đầy đủ vừa thiết lập, ta sẽ xây dựng một thuật toán MCMC trong R có tên `occ.gen1.mcmc.R` để khớp mô hình chiếm cứ tổng quát hơn này, cho phép xác suất phát hiện thay đổi theo địa điểm:

```

1  occ.gen1.mcmc <- function(y,J,W,X,n.mcmc){
2
3  ####
4  #### Libraries and Subroutines
5  ####
6
7  logit.inv <- function(logit){
8    exp(logit)/(1+exp(logit))
9  }
10
11  ####
12  #### Create Variables
13  ####
14
15  n=length(y)
16  pX=dim(X)[2]
17  pW=dim(W)[2]
18  beta.save=matrix(0,pX,n.mcmc)
19  alpha.save=matrix(0,pW,n.mcmc)
20  z.mean=rep(0,n)
21  N.save=rep(0,n.mcmc)
22
23  ####
24  #### Priors and Starting Values
25  ####
26
27  beta.mn=rep(0,pX)
28  alpha.mn=rep(0,pW)
29  beta.sd=1.5
30  alpha.sd=1.5
31  z=rep(0,n)
32  z[y>0]=1
33
34  beta=as.vector(glm(z ~ 0+X,family=binomial())$coefficients)
35  beta.tune=2*abs(beta)
36
37  alpha=as.vector(glm(cbind(y[y>1],J[y>1]-y[y>1]) ~ 0+W[y>1,],family=binomial())$coefficients)
38  alpha.tune=3*abs(alpha)
39
40  ####
41  #### Begin MCMC Loop
42  ####
43
44  for(k in 1:n.mcmc){
45    if(k%%1000==0) cat(k," ")
46
47    ####
48    #### Sample beta

```

```

49 #####
50
51 beta.star=rnorm(pX,beta,beta.tune)
52 mh1=sum(dbinom(z,1,logit.inv(X%%beta.star),log=TRUE))+sum(dnorm(beta.star,beta.mn,beta.sd,log=TRUE))
53 mh2=sum(dbinom(z,1,logit.inv(X%%beta),log=TRUE))+sum(dnorm(beta,beta.mn,beta.sd,log=TRUE))
54 mh=exp(mh1-mh2)
55 if(mh > runif(1)){
56     beta=beta.star
57 }
58 psi=logit.inv(X%%beta)
59
60 #####
61 ##### Sample alpha
62 #####
63
64 alpha.star=rnorm(pW,alpha,alpha.tune)
65 mh1=sum(dbinom(y[z==1],J[z==1],logit.inv(W[z==1,]%%alpha.star),log=TRUE))+sum(dnorm(alpha.star,alpha.mn,alpha.sd,log=TRUE))
66 mh2=sum(dbinom(y[z==1],J[z==1],logit.inv(W[z==1,]%%alpha),log=TRUE))+sum(dnorm(alpha,alpha.mn,alpha.sd,log=TRUE))
67 mh=exp(mh1-mh2)
68 if(mh > runif(1)){
69     alpha=alpha.star
70 }
71 p=logit.inv(W%%alpha)
72
73 #####
74 ##### Sample z
75 #####
76
77 num.tmp=psi*(1-p)^J
78 psi.tmp=num.tmp/(num.tmp+(1-psi))
79 z[y==0]=rbinom(sum(y==0),1,psi.tmp[y==0])
80
81 #####
82 ##### Save Samples
83 #####
84
85 beta.save[,k]=beta
86 alpha.save[,k]=alpha
87 z.mean=z.mean+z/n.mcmc
88 N.save[k]=sum(z)
89
90 }
91 cat("\n")
92
93 #####
94 ##### Write Output
95 #####
96
97 list(beta.save=beta.save,alpha.save=alpha.save,N.save=N.save,z.mean=z.mean,n.mcmc=n.mcmc)
98
99 }

```

100


Ở phần này, ta sẽ áp dụng mô hình chiếm cứ Bayes với xác suất phát hiện và xác suất chiếm cứ không đồng nhất vào dữ liệu loài chim chích liểu (Henden và cộng sự, 2013). Trong đó, ta sử dụng diện tích đã chuẩn hóa và chiều cao cây liểu làm biến giải thích cho cả hai phần: phần chiếm cứ và phần phát hiện của mô hình. Trong đoạn mã R dưới đây, chúng ta sẽ khớp mô hình sử dụng các siêu tham số: $\mu_\alpha = 0, \Sigma_\alpha = \sigma_\alpha^2 I, \mu_\beta = 0, \Sigma_\beta = \sigma_\beta^2 I$, với cả σ_α^2 và σ_β^2 đều bằng 2.25:

```

1 full.df=read.delim("PlosOne-DataFinnmark.txt",header=TRUE,sep="\t")
2 spp.idx=full.df$Species=="Willow Warbler"
3 y=apply(full.df[spp.idx,1:3],1,sum) # 2015 data
4 n=length(y)
5 X=matrix(1,n,3)
6 X[,2]=scale(full.df[spp.idx,"Pland"])
7 X[,3]=scale(full.df[spp.idx,"wheight"])
8 W=matrix(1,n,3)
9 W[,2]=scale(full.df[spp.idx,"Pland"])
10 W[,3]=scale(full.df[spp.idx,"wheight"])
11
12 source("occ.gen1.mcmc.R") # Code Box 23.4
13 n.mcmc=300000
14 set.seed(1)
15 mcmc.out=occ.gen1.mcmc(y=y,J=rep(3,n),W=W,X=X,n.mcmc=n.mcmc)
16
17 layout(matrix(1:2,2,1))
18 matplot(t(mcmc.out$alpha.save),type="l",lty=1)
19 matplot(t(mcmc.out$beta.save),type="l",lty=1)
20
21 layout(matrix(1:6,3,2))
22 hist(mcmc.out$alpha.save[1,-(1:1000)],breaks=30,col=8,xlab=bquote(alpha[0]),prob=TRUE,main="a")
23 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
24 hist(mcmc.out$alpha.save[2,-(1:1000)],breaks=30,col=8,xlab=bquote(alpha[1]),prob=TRUE,main="c")
25 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
26 hist(mcmc.out$alpha.save[3,-(1:1000)],breaks=30,col=8,xlab=bquote(alpha[2]),prob=TRUE,main="e")
27 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
28 hist(mcmc.out$beta.save[1,-(1:1000)],breaks=30,col=8,xlab=bquote(beta[0]),prob=TRUE,main="b")
29 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
30 hist(mcmc.out$beta.save[2,-(1:1000)],breaks=30,col=8,xlab=bquote(beta[1]),prob=TRUE,main="d")
31 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
32 hist(mcmc.out$beta.save[3,-(1:1000)],breaks=40,col=8,xlab=bquote(beta[2]),prob=TRUE,main="f")
33 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)

```

Kết quả của đoạn mã R này được thể hiện qua các đồ thị phân phối hậu nghiệm biên trong **Hình 2**.



Hình 2. Các biểu đồ tần suất hậu nghiệm biên cho các hệ số phát hiện và chiếm cứ: (a) α_0 (hệ số chặn của mô hình phát hiện), (b) β_0 (hệ số chặn của mô hình chiếm cứ), (c) α_1 (hệ số tác động của diện tích lên khả năng phát hiện), (d) β_1 (hệ số tác động của diện tích lên sự chiếm cứ), (e) α_2 (hệ số tác động của chiều cao cây liễu lên khả năng phát hiện), và (f) β_2 (hệ số tác động của chiều cao cây liễu lên sự chiếm cứ). Kết quả này thu được từ việc khớp mô hình chiếm cứ tổng quát theo địa điểm (site-general occupancy model) với dữ liệu chim chích liễu. Các hàm mật độ xác suất tiên nghiệm (Prior PDFs) được hiển thị bằng các đường màu đen để so sánh.

Các biểu đồ tần suất hậu nghiệm biên cho α và β trong **Hình 2** chỉ ra rằng chúng ta có bằng chứng yếu để khẳng định các biến giải thích liên quan đến địa điểm có ảnh hưởng đến khả năng phát hiện và sự chiếm cứ của loài chim chích liễu. Ví dụ, chúng ta đã giảm bớt được sự không chắc chắn về các tham số α_1 và α_2 (hệ số tác động của diện tích và chiều cao cây liễu lên khả năng phát hiện), bởi

vì các phân phối hậu nghiệm biên của chúng chính xác hơn (more precise) so với các phân phối tiên nghiệm. Kết quả cũng tương tự đối với các hệ số chiếm cứ β_1 và β_2 , cho thấy diện tích địa điểm có tác động mạnh hơn một chút so với chiều cao cây liễu lên sự chiếm cứ của loài chim này.

Dựa trên những kết quả này, chúng ta có thể kết luận rằng một mô hình phù hợp hơn cho dữ liệu chim chích liễu sẽ là mô hình chiếm cứ với xác suất phát hiện đồng nhất và sử dụng phân phối tiên nghiệm trực tiếp $p \sim \text{Beta}(\alpha_p, \beta_p)$ như đã mô tả trong phần trước.

Chúng ta có thể tổng quát hóa mô hình chiếm cứ thêm một bước nữa bằng cách cho phép xác suất phát hiện thay đổi theo cả địa điểm và thời điểm khảo sát (p_{ij}), miễn là chúng ta có sẵn các biến giải thích (covariates) cho cả hai yếu tố này. Theo đó, thành phần dữ liệu cho mô hình chiếm cứ tổng quát hoàn toàn này được xác định như sau:

$$y_{ij} \sim \begin{cases} \text{Bern}(p_{ij}), & \text{nếu } z_i = 1 \\ 0, & \text{nếu } z_i = 0 \end{cases}$$

trong đó các xác suất phát hiện được liên kết với các biến giải thích theo địa điểm và thời điểm khảo sát thông qua hàm logit: $\text{logit}(p_{ij}) = w_{ij}\alpha$. Phần còn lại của mô hình chiếm cứ (quy trình sinh thái) vẫn giữ nguyên như mô hình tổng quát trước đó. Phân phối hậu nghiệm cho mô hình chiếm cứ Bayes tổng quát hoàn toàn này là:

$$[z, \alpha, \beta | Y] \propto \prod_{i=1}^n \left(\prod_{j=1}^{J_i} [y_{ij} | \alpha]^{z_i} \mathbf{1}_{\{y_{ij}=0\}}^{1-z_i} \right) [z_i | \beta] [\alpha] [\beta]$$

trong đó $[y_{ij} | \alpha]$ là hàm khối xác suất (PMF) Bernoulli với xác suất $p_{ij} = \frac{\exp(w_{ij}\alpha)}{1 + \exp(w_{ij}\alpha)}$. Với việc thiết lập các phân phối tiên nghiệm chuẩn đa biến tương tự như đã sử dụng trong mô hình trước, chỉ có các phân phối điều kiện đầy đủ cho z_i ($i = 1, \dots, n$) và α là sẽ thay đổi.

Đối với α , phân phối điều kiện đầy đủ là:

$$[\alpha | \cdot] \propto \prod_{i=1}^n \prod_{j=1}^{J_i} [y_{ij} | \alpha]^{z_i} [\alpha] \quad (2.2.4)$$

$$\propto \prod_{\forall z_i=1} \prod_{j=1}^{J_i} [y_{ij} | \alpha] [\alpha] \quad (2.2.5)$$

dẫn đến tỷ lệ chấp nhận M-H (Metropolis-Hastings ratio) là:

$$mh = \frac{\prod_{\forall z_i=1} \prod_{j=1}^{J_i} [y_{ij} | \alpha^{(*)}] [\alpha^{(*)}]}{\prod_{\forall z_i=1} \prod_{j=1}^{J_i} [y_{ij} | \alpha^{(k-1)}] [\alpha^{(k-1)}]}$$

nếu chúng ta sử dụng cùng một phân phối đề xuất bước ngẫu nhiên chuẩn đa biến như trước. Do đó, chúng ta có thể sử dụng bước cập nhật M-H để lấy mẫu α trong thuật toán MCMC.

Phân phối điều kiện đầy đủ cho z_i hơi khác một chút so với ví dụ trước vì cả y_{ij} và p_{ij} đều thay đổi theo địa điểm và đợt khảo sát. Đối với mô hình chiếm cứ tổng quát hoàn toàn, chúng ta chỉ lấy mẫu z_i trong thuật toán MCMC khi $\sum_{j=1}^{J_i} y_{ij} = 0$ (nếu khác 0, ta gán $z_i = 1$). Khi đó, phân phối điều kiện đầy đủ cho z_i là Bernoulli với xác suất:

$$\tilde{\psi}_i = \frac{\psi_i \prod_{j=1}^{J_i} (1 - p_{ij})}{\psi_i \prod_{j=1}^{J_i} (1 - p_{ij}) + 1 - \psi_i}$$

Dựa trên các phân phối điều kiện đầy đủ này, ta xây dựng một thuật toán MCMC có tên là `occ.gen2.mcmc.R` để khớp mô hình chiếm cứ tổng quát hoàn toàn với dữ liệu trong R.

```

1  occ.gen2.mcmc <- function(Y,J,W,X,n.mcmc){
2
3  #####
4  ##### Code Box 23.6
5  #####
6
7  #####
8  ##### Subroutines
9  #####
10
11  logit.inv <- function(logit){
12    exp(logit)/(1+exp(logit))
13  }
14
15  #####
16  ##### Create Variables
17  #####
18
19  n=dim(Y)[1]
20  pX=dim(X)[2]
21  pW=dim(W)[2]
22  beta.save=matrix(0,pX,n.mcmc)
23  alpha.save=matrix(0,pW,n.mcmc)
24  z.mean=rep(0,n)
25  N.save=rep(0,n.mcmc)
26
27  #####
28  ##### Priors and Starting Values
29  #####
30
31  y=apply(Y,1,sum,na.rm=TRUE)
32  y.vec=c(Y)
33  y0.TF=(apply(Y,1,sum)==0)
34  beta.mn=rep(0,pX)
35  alpha.mn=rep(0,pW)
36  beta.sd=1.5
37  alpha.sd=1.5
38  z=rep(0,n)
39  z[!y0.TF]=1
40
41  beta=as.vector(glm(z ~ 0+X,family=binomial())$coefficients)
42  beta.tune=2*abs(beta)
43
44  alpha=as.vector(glm(c(Y[z==1,]) ~ 0+W[rep(z==1,J),],family=binomial())$coefficients)
45  alpha.tune=2*abs(alpha)
46
47  #####
48  ##### Begin MCMC Loop
49  #####
50

```



```

51 for(k in 1:n.mcmc){
52   if(k%%1000==0) cat(k, " ")
53
54   #####
55   ##### Sample beta
56   #####
57
58   beta.star=rnorm(pX,beta,beta.tune)
59   mh1=sum(dbinom(z,1,logit.inv(X%%beta.star),log=TRUE))+sum(dnorm(beta.star,beta.mn,beta.sd,log=TRUE))
60   mh2=sum(dbinom(z,1,logit.inv(X%%beta),log=TRUE))+sum(dnorm(beta,beta.mn,beta.sd,log=TRUE))
61   mh=exp(mh1-mh2)
62   if(mh > runif(1)){
63     beta=beta.star
64   }
65   psi=logit.inv(X%%beta)
66
67   #####
68   ##### Sample alpha
69   #####
70
71   alpha.star=rnorm(pW,alpha,alpha.tune)
72   mh1=sum(dbinom(c(Y[z==1,]),1,logit.inv(W[rep(z==1,J),]%%alpha.star),log=TRUE))
73   +sum(dnorm(alpha.star,alpha.mn,alpha.sd,log=TRUE))
74   mh2=sum(dbinom(c(Y[z==1,]),1,logit.inv(W[rep(z==1,J),]%%alpha),log=TRUE))
75   +sum(dnorm(alpha,alpha.mn,alpha.sd,log=TRUE))
76   mh=exp(mh1-mh2)
77   if(mh > runif(1)){
78     alpha=alpha.star
79   }
80   p=logit.inv(W%%alpha)
81
82   #####
83   ##### Sample z
84   #####
85
86   num.tmp=psi*apply(1-matrix(p,,J),1,prod)
87   psi.tmp=num.tmp/(num.tmp+(1-psi))
88   z[y0.TF]=rbinom(sum(y0.TF),1,psi.tmp[y0.TF])
89
90   #####
91   ##### Save Samples
92   #####
93
94   beta.save[,k]=beta
95   alpha.save[,k]=alpha
96   z.mean=z.mean+z/n.mcmc
97   N.save[k]=sum(z)
98
99 }
100 cat("\n")
101
102 #####

```

```

103 ##### Write Output
104 #####
105
106 list(beta.save=beta.save,alpha.save=alpha.save,N.save=N.save,z.mean=z.mean,n.mcmc=n.mcmc)
107
108 }
109

```

Ta sẽ áp dụng mô hình chiếm cứ tổng quát hoàn toàn vào cùng bộ dữ liệu chim chích liểu đó, nhưng lần này cho phép có sự không đồng nhất qua $J = 3$ đợt lấy mẫu. Chúng ta sẽ sử dụng các phiên bản đã chuẩn hóa của chỉ số đợt khảo sát và chiều cao cây liểu làm biến giải thích cho xác suất phát hiện (lưu ý rằng chiều cao cây liểu không thay đổi qua các đợt khảo sát). Đối với các biến giải thích cho sự chiếm cứ, ta cũng sử dụng diện tích địa điểm và chiều cao cây liểu đã chuẩn hóa giống như ở phần trước. Đoạn mã R sau đây thực hiện việc khớp mô hình chiếm cứ tổng quát hoàn toàn vào dữ liệu chim chích liểu sử dụng thuật toán MCMC ở trên:

```

1  ###
2  ### Fit General Occupancy Model 2
3  ###
4
5  full.df=read.delim("PlosOne-DataFinnmark.txt",header=TRUE,sep="\t")
6  spp.idx=full.df$Species=="Willow Warbler"
7  Y=as.matrix(full.df[spp.idx,1:3])
8  n=dim(Y)[1]
9  J=dim(Y)[2]
10 X=matrix(1,n,3)
11 X[,2]=scale(full.df[spp.idx,"Pland"])
12 X[,3]=scale(full.df[spp.idx,"wheight"])
13 W=matrix(1,n*J,3)
14 W[,2]=scale(c(col(Y)))
15 W[,3]=rep(scale(full.df[spp.idx,"wheight"]),J)
16
17 source("occ.gen2.mcmc.R") # Code Box 23.6
18 n.mcmc=300000
19 set.seed(1)
20 mcmc.out=occ.gen2.mcmc(Y=Y,J=J,W=W,X=X,n.mcmc=n.mcmc)
21
22 hist(mcmc.out$alpha.save[1,-(1:1000)],breaks=30,col=8,xlab=bquote(alpha[0]),prob=TRUE,main="a")
23 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
24 hist(mcmc.out$alpha.save[2,-(1:1000)],breaks=30,col=8,xlab=bquote(alpha[1]),prob=TRUE,main="c")
25 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
26 hist(mcmc.out$alpha.save[3,-(1:1000)],breaks=30,col=8,xlab=bquote(alpha[2]),prob=TRUE,main="e")
27 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
28 hist(mcmc.out$beta.save[1,-(1:1000)],breaks=30,col=8,xlab=bquote(beta[0]),prob=TRUE,main="b")
29 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
30 hist(mcmc.out$beta.save[2,-(1:1000)],breaks=30,col=8,xlab=bquote(beta[1]),prob=TRUE,main="d")
31 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
32 hist(mcmc.out$beta.save[3,-(1:1000)],breaks=30,col=8,xlab=bquote(beta[2]),prob=TRUE,main="f")
33 curve(dnorm(x,0,1.5),lwd=2,add=TRUE)
34 dev.off()


```

```

35 mean(mcmc.out$N.save[-(1:1000)])
36
37 quantile(mcmc.out$N.save[-(1:1000)],c(0.025,0.975))

```

Các phân phối hậu nghiệm biên liên quan đến α và β được thể hiện trong **Hình 3**.



Hình 3. Các biểu đồ tần suất hậu nghiệm biên cho các hệ số phát hiện: (a) α_0 (hệ số chặn phát hiện), (b) β_0 (hệ số chặn chiếm cứ), (c) α_1 (chỉ số đợt khảo sát), (d) β_1 (diện tích), (e) α_2 (chiều cao cây liễu - ảnh hưởng đến phát hiện), và (f) β_2 (chiều cao cây liễu - ảnh hưởng đến chiếm cứ). Kết quả này thu được từ việc khớp mô hình chiếm cứ tổng quát hoàn toàn với dữ liệu chim chích liễu. Các hàm mật độ xác suất tiên nghiệm (Prior PDFs) được hiển thị bằng các đường màu đen để so sánh.

Các kết quả trong **Hình 3** chỉ ra rằng, đối với xác suất phát hiện chim chích liểu, ta chỉ thấy xuất hiện các tác động yếu của chỉ số đợt khảo sát và chiều cao cây liểu lên chúng, ngược lại xuất hiện tác động rõ rệt của diện tích địa điểm lên sự chiếm cứ của loài này (điều này đúng như kỳ vọng của chúng ta vì nhiều cá thể hơn có thể cư trú ở những khu vực rộng lớn hơn). Hơn nữa, giá trị trung bình hậu nghiệm cho tổng số địa điểm bị chiếm cứ là $E(N|Y) = 20.6$ với khoảng tin cậy 95% là (18, 27). Như vậy, ta ước lượng có khoảng 56% số địa điểm thực sự bị chiếm cứ, mặc dù chim chích liểu chỉ được phát hiện tại 18 trên tổng số 37 địa điểm (tương ứng 48.6%).

Như vậy, từ kết quả trên, ta thấy được 2 vấn đề quan trọng:

- Về sinh thái: Diện tích sinh cảnh là yếu tố then chốt quyết định sự phân bố của chim chích liểu, trong khi chiều cao cây hay thời điểm khảo sát không ảnh hưởng đáng kể đến khả năng phát hiện giống loài.
- Về chiếm cứ: Việc sử dụng mô hình chiếm cứ đã giúp hiệu chỉnh sai số quan sát. Ta ước tính tỷ lệ chiếm cứ thực tế của loài là 56%, cao hơn đáng kể so với tỷ lệ quan sát thô ban đầu là 48.6%. Điều này cho thấy có khoảng 2-3 địa điểm quần thể đang tồn tại nhưng chưa được phát hiện, cho thấy được việc quan sát lặp lại là có hiệu quả trong mô hình.

2.3 Mô hình chiếm cứ Probit

Bên cạnh phương pháp Metropolis-Hastings sử dụng hàm liên kết Logit, một cách tiếp cận khác hiệu quả về mặt tính toán là sử dụng Biến phụ trợ (Auxiliary Variables) theo đề xuất của Albert và Chib (1993). Trong Chương 20, chúng ta đã được giới thiệu về khái niệm thiết lập các mô hình dữ liệu nhị phân Bayes phân cấp sử dụng các biến phụ trợ (auxiliary variables).

Cách tiếp cận cơ bản là đưa vào một biến phụ trợ mới cho mỗi quan sát; biến này nhận giá trị thực và tuân theo một phân phối chuẩn có điều kiện với phương sai bằng 1. Mỗi biến phụ trợ đóng vai trò chỉ thị xem dữ liệu quan sát được là 1 hay 0, dựa trên việc giá trị của biến phụ trợ đó lớn hơn hay nhỏ hơn 0.

Ưu điểm lớn nhất của phương pháp này là đưa mô hình về dạng liên hợp (conjugate), cho phép sử dụng thuật toán Gibbs Sampling hoàn toàn, giúp đơn giản hóa quá trình lấy mẫu và tăng tốc độ hội tụ.

Việc mở rộng mô hình hồi quy nhị phân Probit (Chương 20) sang bối cảnh chiếm cứ tổng quát là khá dễ dàng, nhưng đòi hỏi hai tập hợp biến ẩn, một cho quy trình phát hiện (p) và một cho quy trình chiếm cứ (ψ). Như đã mô tả ở Chương 20, chúng ta viết mô hình dữ liệu dưới dạng một hỗn hợp của các số 0 và 1 như sau:

$$y_{ij} = \begin{cases} 0, & \text{nếu } z_i = 0 \\ 0, & \text{nếu } z_i = 1, u_{ij} \leq 0 \\ 1, & \text{nếu } z_i = 1, u_{ij} > 0 \end{cases} \quad (2.3.1)$$

trong đó, chúng ta cũng xác định quy trình chiếm cứ tiềm ẩn z_i là một hỗn hợp của các số 0 và 1, chính xác như cách chúng ta đã trình bày trong mô hình chiếm cứ Probit ở Chương 20:

$$z_i = \begin{cases} 0, & \text{nếu } v_i \leq 0 \\ 1, & \text{nếu } v_i > 0 \end{cases} \quad (2.3.2)$$

trong đó $u_{ij} \sim N(w_{ij}\alpha, 1)$ và $v_i \sim N(x_i\beta, 1)$, với các phân phối tiên nghiệm chuẩn đa biến như chúng ta đã định nghĩa ở phần trước.

Ta có một nhận xét là cách thiết lập mô hình biến phụ trợ này tương đương về mặt toán học với mô hình chiếm cứ tổng quát ở phần trước, nhưng với các hàm liên kết được chỉ định là Probit (Φ^{-1})

thay vì Logit, sao cho $\Phi^{-1}(p_{ij}) = w_{ij}\alpha$ và $\Phi^{-1}(\psi_i) = x_i\beta$.

Ta nói chúng tương đương về mặt toán học vì hàm Probit hay Logit đều dùng hàm cong hình chữ S (Logic dùng Logistic function và Probit dùng hàm CDF của phân phối chuẩn). Hai đường cong này có hình dáng gần như y hệt nhau. Vì vậy, kết quả (ψ, p) thu được từ hai mô hình này thường không khác biệt đáng kể. Ta dùng Probit vì nó có thể áp dụng thuật toán Gibbs Sampling thay vì Metropolis-Hastings.

Mô hình chiếm cứ tổng quát với các biến phụ trợ dẫn đến phân phối hậu nghiệm sau:

$$[U, v, z, \alpha, \beta | Y] \propto \prod_{i=1}^n \left(\prod_{j=1}^{J_i} [y_{ij} | z_i, u_{ij}] [u_{ij} | \alpha] \right) [z_i | v_i] [v_i | \beta] [\alpha] [\beta] \quad (2.3.3)$$

Để xây dựng một thuật toán MCMC nhằm khớp mô hình chiếm cứ tổng quát với các biến phụ trợ, chúng ta phải có các phân phối điều kiện đầy đủ cho từng biến và tham số.

Phân phối điều kiện đầy đủ cho các hệ số chiếm cứ β tỷ lệ thuận với các thành phần của phân phối kết hợp (2.3.3) có liên quan đến β ; điều này dẫn đến:

$$[\beta | \cdot] \propto \prod_{i=1}^n [v_i | \beta] [\beta] \quad (2.3.4)$$

Biểu thức này có dạng chính xác giống hệt như trong mô hình hồi quy tuyến tính Bayes ở **Chương 11**. Do đó, chúng ta có thể 'mượn' lại kết quả đã dẫn xuất ở chương đó, bằng cách sử dụng v làm biến phản hồi và đặt tham số phương sai bằng 1. Vì vậy, phân phối điều kiện đầy đủ cho β là một phân phối chuẩn đa biến liên hợp (conjugate multivariate normal), sao cho $[\beta | \cdot] = \mathcal{N}(A^{-1}b, A^{-1})$, trong đó:

$$b \equiv X'v + \Sigma_{\beta}^{-1}\mu_{\beta} \quad (2.3.5)$$

$$A \equiv X'X + \Sigma_{\beta}^{-1} \quad (2.3.6)$$

Kết luận lại, chúng ta có thể lấy mẫu β bằng cách sử dụng bước cập nhật Gibbs trong thuật toán MCMC của mình.

Phân phối điều kiện đầy đủ cho các hệ số phát hiện α tương tự như của β , ngoại trừ việc chúng ta phải theo dõi hai tích số (hai vòng lặp):

$$[\alpha | \cdot] \propto \left(\prod_{i=1}^n \prod_{j=1}^{J_i} [u_{ij} | \alpha]^{z_i} \right) [\alpha] \quad (2.3.7)$$

$$\propto \left(\prod_{\forall z_i=1} \prod_{j=1}^{J_i} [u_{ij} | \alpha] \right) [\alpha] \quad (2.3.8)$$

$$\propto \left(\prod_{\forall z_i=1} \prod_{j=1}^{J_i} \exp \left(-\frac{1}{2} (u_{ij} - \mathbf{w}'_{ij}\alpha)^2 \right) \right) \exp \left(-\frac{1}{2} (\alpha - \mu_{\alpha})' \Sigma_{\alpha}^{-1} (\alpha - \mu_{\alpha}) \right) \quad (2.3.9)$$

$$\propto \exp \left(-\frac{1}{2} \sum_{\forall z_i=1} \sum_{j=1}^{J_i} (u_{ij} - w'_{ij}\alpha)^2 \right) \exp \left(-\frac{1}{2} (\alpha - \mu_{\alpha})' \Sigma_{\alpha}^{-1} (\alpha - \mu_{\alpha}) \right) \quad (2.3.10)$$

$$\propto \exp \left(-\frac{1}{2} \left(-2 \left(\sum_{\forall z_i=1} \sum_{j=1}^{J_i} u_{ij} \mathbf{w}'_{ij} \right) \alpha + \alpha' \left(\sum_{\forall z_i=1} \sum_{j=1}^{J_i} \mathbf{w}_{ij} \mathbf{w}'_{ij} \right) \alpha - 2\mu'_{\alpha} \Sigma_{\alpha}^{-1} \alpha + \alpha' \Sigma_{\alpha}^{-1} \alpha \right) \right) \quad (2.3.11)$$

$$\propto \exp \left(-\frac{1}{2} \left(-2 \left(\sum_{\forall z_i=1} \sum_{j=1}^{J_i} u_{ij} \mathbf{w}'_{ij} + \mu'_{\alpha} \Sigma_{\alpha}^{-1} \right) \alpha + \alpha' \left(\sum_{\forall z_i=1} \sum_{j=1}^{J_i} \mathbf{w}_{ij} \mathbf{w}'_{ij} + \Sigma_{\alpha}^{-1} \right) \alpha \right) \right) \quad (2.3.12)$$

$$\propto \exp\left(-\frac{1}{2}(-2b'\alpha + \alpha' A \alpha)\right) \quad (2.3.13)$$

dẫn đến $[\alpha|\cdot] = \mathcal{N}(A^{-1}b, A^{-1})$ với

$$b' \equiv \sum_{\forall z_i=1} \sum_{j=1}^{J_i} u_{ij} w'_{ij} + \mu_\alpha \Sigma_\alpha^{-1} \quad (2.3.14)$$

$$A \equiv \sum_{\forall z_i=1} \sum_{j=1}^{J_i} w_{ij} w'_{ij} + \Sigma_\alpha^{-1} \quad (2.3.15)$$

Phân phối điều kiện đầy đủ này cũng có tính liên hợp, và ta có thể lấy mẫu α bằng cách sử dụng cập nhật Gibbs trong thuật toán MCMC.

Với các biến phụ trợ, chúng ta có thể thiết lập phân phối điều kiện đầy đủ như sau:

- Đối với v_i (Biến phụ trợ cho Chiếm cứ - Occupancy):

$$[v_i|\cdot] \propto [z_i|v_i][v_i|\beta] \quad (2.3.16)$$

$$\propto (\mathbf{1}_{\{v_i>0\}} \mathbf{1}_{\{z_i=1\}} + \mathbf{1}_{\{v_i\leq 0\}} \mathbf{1}_{\{z_i=0\}})[v_i|\beta] \quad (2.3.17)$$

$$= \begin{cases} TN(\mathbf{x}_i\beta, 1)_0^\infty, & \text{nếu } z_i = 1 \\ TN(\mathbf{x}_i\beta, 1)_{-\infty}^0, & \text{nếu } z_i = 0 \end{cases} \quad (2.3.18)$$

Trong đó 'TN' là Phân phối Chuẩn bị cắt cụt, với cận dưới là chỉ số dưới và cận trên là chỉ số trên. Do đó, ta có thể cập nhật v_i bằng Gibbs dựa trên trạng thái hiện tại của z_i .

- Đối với u_{ij} (Biến phụ trợ cho Phát hiện - Detection): Tương tự như v_i , nhưng ta chỉ lấy mẫu u_{ij} khi $z_i = 1$ (vì quá trình phát hiện chỉ xảy ra khi loài có mặt).

$$[u_{ij}|\cdot] \propto [y_{ij}|u_{ij}][u_{ij}|\alpha] \quad (2.3.19)$$

$$\propto (\mathbf{1}_{\{u_{ij} > 0\}} \mathbf{1}_{\{y_{ij} = 1\}} + \mathbf{1}_{\{u_{ij} \leq 0\}} \mathbf{1}_{\{y_{ij}=0\}})[u_{ij}|\alpha] \quad (2.3.20)$$

$$= \begin{cases} TN(\mathbf{w}_i\alpha, 1)_0^\infty, & \text{nếu } y_{ij} = 1 \\ TN(\mathbf{w}_i\alpha, 1)_{-\infty}^0, & \text{nếu } y_{ij} = 0 \end{cases} \quad (2.3.21)$$

Do đó, ta cũng có thể cập nhật u_{ij} bằng Gibbs dựa trên dữ liệu quan sát y_{ij} .

Cuối cùng, chúng ta cần xác định phân phối điều kiện đầy đủ cho quá trình chiếm cứ tiềm ẩn z_i . Tương tự như các biến nhị phân tiềm ẩn khác, phân phối điều kiện đầy đủ đi kèm là Bernoulli. Thực tế, phân phối này cho z_i giống hệt phân phối mà chúng ta đã thiết lập cho mô hình chiếm cứ tổng quát ở chương trước, trong đó $[z_i|\cdot] = \text{Bern}(\tilde{\psi}_i)$ và:

$$\tilde{\psi}_i = \frac{\psi_i \prod_{j=1}^{J_i} (1 - p_{ij})}{\psi_i \prod_{j=1}^{J_i} (1 - p_{ij}) + 1 - \psi_i} \quad (2.3.22)$$

với lưu ý rằng $\psi_i = \Phi(x_i\beta)$ (sử dụng hàm chuẩn tích lũy thay vì logit) và chúng ta chỉ thực hiện lấy mẫu z_i trong thuật toán MCMC khi tổng số quan sát bằng 0 ($\sum_{j=1}^{J_i} y_{ij} = 0$).

Như vậy, chúng ta có thể khớp một mô hình chiếm cứ Bayes tổng quát bằng cách sử dụng thuật toán MCMC Gibbs toàn phần, trong đó ta có thể lấy mẫu tất cả các tham số từ các phân phối đã biết.

Thuật toán MCMC thu được phức tạp hơn đáng kể so với thuật toán chúng ta đã sử dụng với hàm liên kết logit ở các phần trước. Tuy nhiên, hàm liên kết probit (được tạo ra thông qua các biến phụ trợ) lại loại bỏ hoàn toàn nhu cầu phải chỉnh sửa thuật toán. Do đó, chúng ta có thể áp dụng phiên bản probit của Mô hình chiếm cứ tổng quát (thay vì sử dụng hàm logit trước đó) vào các tình huống có các dữ liệu khác nhau mà không cần thay đổi cấu trúc thuật toán MCMC.

Ngoài ra, ta cũng có thể đơn giản hóa mô hình chiếm cứ tổng quát, ví dụ như bằng cách thay thế các biến phụ trợ phát hiện bằng một xác suất phát hiện đồng nhất p duy nhất (như đã trình bày trong đồ án ở phần 2.2). Kết quả này vẫn tạo ra một thuật toán Gibbs toàn phần, vì phân phối điều kiện đầy đủ cho p sẽ là phân phối Beta liên hợp.

Từ đó, ta xây dựng thuật toán MCMC gọi là `occ.aux.mcmc.R` trong R để khớp với mô hình chiếm cứ probit theo dữ liệu như sau:

```

1  occ.aux.mcmc <- function(Y,J,W,X,n.mcmc){
2
3  ####
4  #### Code Box 23.8
5  ####
6
7  ####
8  #### Libraries and Subroutines
9  ####
10
11 rtn <- function(n,mu,sig2,low,high){
12   flow=pnorm(low,mu,sqrt(sig2))
13   fhigh=pnorm(high,mu,sqrt(sig2))
14   u=runif(n)
15   tmp=flow+u*(fhigh-flow)
16   x=qnorm(tmp,mu,sqrt(sig2))
17   x
18 }
19
20 ####
21 #### Setup Variables
22 ####
23
24 n=dim(Y)[1]
25 p.X=dim(X)[2]
26 p.W=dim(W)[2]
27 n.burn=round(0.25*n.mcmc)
28
29 z.mean=rep(0,n)
30 beta.save=matrix(0,p.X,n.mcmc)
31 alpha.save=matrix(0,p.W,n.mcmc)
32 N.save=rep(0,n.mcmc)
33
34 ####
35 #### Hyperparameters and Starting Values
36 ####
37
38 beta=rep(0,p.X)
39 alpha=rep(0,p.W)
40 Xbeta=X%*%beta
41 Walpha=W%*%alpha
42 psi=pnorm(Xbeta)
43 p=pnorm(Walpha)
44 Y.sum=apply(Y,1,sum)

```

```

45 z=rep(0,n)
46 z[Y.sum==0]=0
47 n0=sum(z==0)
48 n1=sum(z==1)
49 z.1.big=rep(z==1,J)
50
51 v=rep(0,n)
52 u=rep(0,n*J)
53
54 y=as.vector(Y)
55 ny0=sum(y==0)
56 ny1=sum(y==1)
57
58 Sig.beta=(1^2)*diag(p.X)
59 Sig.alpha=(1^2)*diag(p.W)
60 Sig.beta.inv=solve(Sig.beta)
61 Sig.alpha.inv=solve(Sig.alpha)
62
63 mu.beta=rep(0,p.X)
64 mu.alpha=rep(0,p.W)
65
66 XprimeX=t(X)%*%X
67 A.beta=XprimeX+Sig.beta.inv
68 A.beta.chol=chol(A.beta)
69 Sig.beta.inv.times.mu.beta=Sig.beta.inv%*%mu.beta
70 Sig.alpha.inv.times.mu.alpha=Sig.alpha.inv%*%mu.alpha
71
72 #####
73 ##### Begin Gibbs Loop
74 #####
75
76 for(k in 1:n.mcmc){
77   if(k%%1000==0) cat(k," ")
78
79   #####
80   ##### Sample v
81   #####
82
83   v[z==0]=rtn(n0,Xbeta[z==0],1,-Inf,0)
84   v[z==1]=rtn(n1,Xbeta[z==1],1,0,Inf)
85
86   #####
87   ##### Sample U
88   #####
89   ##### Note: sampling the `extra' u where z=0 is wasteful, but ok to do.
90   #####
91
92   u[y==0]=rtn(ny0,Walpha[y==0],1,-Inf,0)
93   u[y==1]=rtn(ny1,Walpha[y==1],1,0,Inf)
94
95   #####
96   ##### Sample beta

```



```

97 #####
98
99 b.beta=t(X)%*%v+Sig.beta.inv.times.mu.beta
100 beta=backsolve(A.beta.chol, backsolve(A.beta.chol, b.beta, transpose = TRUE) + rnorm(p.X))
101 Xbeta=X%*%beta
102 psi=pnorm(Xbeta)
103
104 #####
105 ##### Sample alpha
106 #####
107
108 W.tmp=W[z.1.big,]
109 A.alpha=t(W.tmp)%*%W.tmp+Sig.alpha.inv
110 A.alpha.chol=chol(A.alpha)
111 b.alpha=t(W.tmp)%*%u[z.1.big]+Sig.alpha.inv.times.mu.alpha
112 alpha=backsolve(A.alpha.chol, backsolve(A.alpha.chol, b.alpha, transpose = TRUE) + rnorm(p.W))
113 Walpha=W%*%alpha
114 p=pnorm(Walpha)
115
116 #####
117 ##### Sample z
118 #####
119
120 psi.numer=psi*apply(1-matrix(p,n,J),1,prod)
121 psi.tmp=psi.numer/(psi.numer+1-psi)
122 z[Y.sum==0]=rbinom(sum(Y.sum==0),1,psi.tmp[Y.sum==0])
123 z[Y.sum>0]=1
124 n0=sum(z==0)
125 n1=sum(z==1)
126 z.1.big=rep(z==1,J)
127
128 #####
129 ##### Save Samples
130 #####
131
132 beta.save[,k]=beta
133 alpha.save[,k]=alpha
134 if(k > n.burn){
135     z.mean=z.mean+z/(n.mcmc-n.burn)
136 }
137 N.save[k]=sum(z)
138
139 }
140 cat("\n")
141
142 #####
143 ##### Write Output
144 #####
145
146 list(alpha.save=alpha.save,beta.save=beta.save,z.mean=z.mean,N.save=N.save,n.mcmc=n.mcmc)
147
148 }

```

Một vài lưu ý cho đoạn code trên trước khi ta áp dụng dữ liệu vào:

- Hàm (rtn) được sử dụng để lấy mẫu các biến ngẫu nhiên chuẩn bị cắt cụt v_i và u_{ij} , cũng như kỹ thuật backsolve để lấy mẫu các vector ngẫu nhiên chuẩn đa biến có tương quan α và β .
- Đoạn code lấy mẫu tất cả các u_{ij} (ngay cả ở những nơi $z_i = 0$) để lập trình đơn giản hơn, điều này không làm ảnh hưởng đến kết quả.
- Giả định rằng số lượng các đợt khảo sát lặp lại là giống nhau cho tất cả các địa điểm ($J_i = J$ với $i = 1, \dots, n$). Tuy nhiên có thể thiết kế lại dựa trên ma trận W .
- Cuối cùng, ta giả định rằng $\Sigma_\alpha \equiv I$ và $\Sigma_\beta \equiv I$, tức là về mặt tiên nghiệm, tất cả các hệ số hồi quy đều độc lập với nhau và có phương sai bằng 1.

Sau đó, ta áp dụng mô hình này vào cùng bộ dữ liệu chim chích liểu từ Na Uy đã giới thiệu ở phần trước, sử dụng đoạn mã R sau:

```

1 full.df=read.delim("PlosOne-DataFinnmark.txt",header=TRUE,sep="\t")
2 spp.idx=full.df$Species=="Willow Warbler"
3 Y=as.matrix(full.df[spp.idx,1:3])
4 n=dim(Y)[1]
5 J=dim(Y)[2]
6 X=matrix(1,n,3)
7 X[,2]=scale(full.df[spp.idx,"Pland"])
8 X[,3]=scale(full.df[spp.idx,"wheight"])
9 W=matrix(1,n*J,3)
10 W[,2]=scale(c(col(Y)))
11 W[,3]=rep(scale(full.df[spp.idx,"wheight"]),J)
12
13 source("occ.aux.mcmc.R") # Code Box 23.8
14 n.mcmc=100000
15 set.seed(1)
16 mcmc.out=occ.aux.mcmc(Y=Y,J=J,W=W,X=X,n.mcmc=n.mcmc)
17
18 layout(matrix(1:2,2,1))
19 matplot(t(mcmc.out$alpha.save),type="l",lty=1)
20 abline(h=0,col=8)
21 matplot(t(mcmc.out$beta.save),type="l",lty=1)
22 abline(h=0,col=8)
23
24 layout(matrix(1:6,3,2))
25 hist(mcmc.out$alpha.save[1,-(1:1000)],breaks=30,col=8,xlab=bquote(alpha[0]),prob=TRUE,main="a")
26 curve(dnorm(x,0,1),lwd=2,add=TRUE)
27 hist(mcmc.out$alpha.save[2,-(1:1000)],breaks=30,col=8,xlab=bquote(alpha[1]),prob=TRUE,main="c")
28 curve(dnorm(x,0,1),lwd=2,add=TRUE)
29 hist(mcmc.out$alpha.save[3,-(1:1000)],breaks=30,col=8,xlab=bquote(alpha[2]),prob=TRUE,main="e")
30 curve(dnorm(x,0,1),lwd=2,add=TRUE)
31 hist(mcmc.out$beta.save[1,-(1:1000)],breaks=30,col=8,xlab=bquote(beta[0]),prob=TRUE,main="b")
32 curve(dnorm(x,0,1),lwd=2,add=TRUE)
33 hist(mcmc.out$beta.save[2,-(1:1000)],breaks=30,col=8,xlab=bquote(beta[1]),prob=TRUE,main="d")
34 curve(dnorm(x,0,1),lwd=2,add=TRUE)
35 hist(mcmc.out$beta.save[3,-(1:1000)],breaks=30,col=8,xlab=bquote(beta[2]),prob=TRUE,main="f")
36 curve(dnorm(x,0,1),lwd=2,add=TRUE)


```

```

37 mean(mcmc.out$N.save[-(1:1000)])
38
39 quantile(mcmc.out$N.save[-(1:1000)],c(0.025,0.975))

```

Các phân phối hậu nghiệm biên liên quan đến α và β được thể hiện trong **Hình 4**.



Hình 4. Các biểu đồ tần suất hậu nghiệm biên cho các hệ số phát hiện: (a) α_0 (hệ số chặn phát hiện), (b) β_0 (hệ số chặn chiếm cứ), (c) α_1 (chỉ số đợt khảo sát), (d) β_1 (diện tích), (e) α_2 (chiều cao cây liễu - ảnh hưởng đến phát hiện), và (f) β_2 (chiều cao cây liễu - ảnh hưởng đến chiếm cứ). Kết quả này thu được từ việc khớp mô hình chiếm cứ tổng quát hoàn toàn với dữ liệu chim chích liễu. Các hàm mật độ xác suất tiên nghiệm (Prior PDFs) được hiển thị bằng các đường màu đen để so sánh.

Kết quả về cơ bản giống hệt với kết quả thu được từ phiên bản logit của cùng mô hình đó (**Hình 3**). Cụ thể,

- Chỉ số đợt khảo sát và chiều cao cây liễu dường như không ảnh hưởng mạnh đến xác suất phát hiện.
- Tuy nhiên, diện tích địa điểm lại cho thấy mối tương quan rõ rệt với sự chiếm cứ cao hơn của loài.

Lưu ý rằng giá trị thực tế của các phân phối hậu nghiệm biên α và β không có sự khác biệt lớn giữa hai mô hình, chủ yếu khác nhau giữa hàm liên kết logit và probit. Trong trường hợp này, việc lựa chọn hàm liên kết không làm ảnh hưởng đến kết luận cuối cùng. Thực tế, trung bình hậu nghiệm cho tổng số địa điểm bị chiếm cứ là $E(N|Y) = 20.8$ với khoảng tin cậy 95% là (18, 27), kết quả này rất tương đồng với mô hình logit trước đó ($E(N|Y) = 20.7$, khoảng tin cậy (18, 27)).

2.4 Một vài khái niệm mở rộng

Mô hình chiếm cứ đã trở nên cực kỳ phổ biến trong giới sinh thái học từ đầu những năm 2000, mặc dù thực tế là chúng ít được thảo luận hoặc sử dụng bởi các nhà thống kê thuần túy.

Cơ chế 'âm tính giả' (false negative) trong các nghiên cứu chiếm cứ – nguyên nhân dẫn đến sai số đo lường nhị phân – là đặc thù khá riêng biệt của ngành sinh thái học động vật hoang dã, dù hiện nay các mô hình này đã được áp dụng trong nhiều lĩnh vực khác.

Mặc dù báo cáo này tập trung vào mô hình chiếm cứ đơn loài (Single-species Occupancy Model) với các biến thể từ đơn giản đến tổng quát, nhưng lĩnh vực mô hình hóa chiếm cứ hiện đại đã mở rộng ra rất nhiều hướng đi mới để giải quyết các bài toán sinh thái phức tạp hơn. Thực tế, hàng loạt các mở rộng và ứng dụng của mô hình chiếm cứ đã được phát triển. Có thể kể đến một vài ví dụ: Mô hình chiếm cứ đa loài, Mô hình chiếm cứ không gian tường minh, Mô hình chiếm cứ động và đa mùa.

Ngoài ra, việc đánh giá độ phù hợp của mô hình (Goodness-of-fit) cũng là một khía cạnh quan trọng cần được đầu tư kỹ lưỡng hơn trong các nghiên cứu chuyên sâu, thông qua các phương pháp như tính toán phần dư hoặc kiểm định bootstrap.

Chương 3

Ứng dụng thực tế mô hình trên dữ liệu chuẩn Vịt cổ xanh Bắc Mỹ

Trong chương này, ta sẽ áp dụng những kiến thức về việc xây dựng các phân phối tiên nghiệm và hậu nghiệm cho mô hình ở chương trước, dùng để Phân tích các yếu tố ảnh hưởng đến sự phân bố của loài Vịt cổ xanh (*Mallard*) sử dụng Mô hình Chiếm cứ Bayes (*Probit Link*).

Chúng ta sẽ lấy dữ liệu từ gói `unmarked` có sẵn trong R, với dữ liệu Vịt cổ xanh Bắc Mỹ (`mallard`). Mục tiêu của chúng ta là Tìm hiểu xem Độ cao (Elevation) và Diện tích rừng (Forest) ảnh hưởng thế nào đến việc vịt chọn nơi ở (ψ). Đồng thời xem Nỗ lực tìm kiếm (trong bộ dữ liệu là độ dài quãng đường) ảnh hưởng thế nào đến khả năng phát hiện (p).

Trước tiên, ta sẽ tìm hiểu thông tin chi tiết về dữ liệu như sau:

- **Kích thước mẫu (N):** 239 địa điểm khảo sát.
- **Số lần lặp lại (J):** Mỗi địa điểm được khảo sát 3 lần
- **Biến phụ thuộc:** Tình trạng phát hiện loài (1 = Thấy, 0 = Không thấy). Dữ liệu gốc là số đếm, ta chuyển sang dạng nhị phân bằng lệnh R.
- **Biến giải thích:**
 - Cho xác suất chiếm cứ ψ :
 - * Độ cao (Elevation): Độ cao so với mực nước biển
 - * Độ che phủ rừng (Forest): Tỷ lệ diện tích rừng tại điểm khảo sát
 - Cho xác suất phát hiện p :
 - * Chỉ số nỗ lực (Ivel) đại diện cho nỗ lực tìm kiếm (độ dài tuyến khảo sát)

Ta mong muốn ước lượng tác động của độ cao và rừng đến sự phân bố ủa Vịt cổ xanh (tương ứng với xác suất chiếm cứ ψ) và tổng số địa điểm thực sự có loài này sinh sống N .

Ta có đoạn code R để tải và đọc dữ liệu như sau:

```
1  #Cài đặt các thư viện cần thiết
2  if(!require(unmarked)) install.packages("unmarked")
3  if(!require(truncnorm)) install.packages("truncnorm") # Cần cho mô hình Probit
4  if(!require(mvtnorm)) install.packages("mvtnorm")      # Cần cho phân phối chuẩn đa biến
5
6  library(unmarked)
7  library(truncnorm)
8  library(mvtnorm)
9
10 #Tải và Làm sạch dữ liệu
11 data(mallard) # tải 3 dữ liệu: mallard.y, mallard.site, mallard.obs
12
13 # Trích xuất lịch sử quan sát (y)
14 y_count <- as.matrix(mallard.y)
15 # CHUYỂN ĐỔI SANG NHỊ PHÂN
16 y_raw <- ifelse(y_count > 0, 1, 0)
```

```

17 # Trích xuất biến môi trường (cho Psi)
18 # Chúng ta chọn 'elev' (độ cao) và 'forest' (độ che phủ rừng)
19 elev <- mallard.site$elev
20 forest <- mallard.site$forest
21
22
23 # Trích xuất biến phát hiện (cho p)
24 # Chúng ta chọn 'ivel' (chỉ số nỗ lực khảo sát)
25 ivel_raw <- as.matrix(mallard.obs$ivel)

```

Tiếp theo, ta sẽ thực hiện 1 vài bước tiền xử lý dữ liệu:

- Chuyển đổi dữ liệu đếm sang dạng 0/1 (do dữ liệu y ban đầu là giá trị số con Vịt cổ xanh quan sát được)
- Xử lý dữ liệu khuyết, loại bỏ các hàng có dữ liệu bị thiếu ở bất kỳ biến nào
- Sau khi xử lý dữ liệu khuyết, ta chuẩn hóa lại dữ liệu (dù bộ dữ liệu đã được chuẩn hóa từ đầu)

Ta có đoạn mã R thực hiện xử lý dữ liệu như sau:

```

1 #Xử lý dữ liệu khuyết (NA)
2 valid_idx <- complete.cases(y_raw, elev, forest, ivel_raw)
3 y <- y_raw[valid_idx, ]
4 elev <- elev[valid_idx]
5 forest <- forest[valid_idx]
6 ivel <- ivel_raw[valid_idx, ]
7
8 #Chuẩn hóa dữ liệu (Standardization)
9 elev_z <- (elev - mean(elev)) / sd(elev)
10 forest_z <- (forest - mean(forest)) / sd(forest)
11 ivel_z <- (ivel - mean(ivel, na.rm=TRUE)) / sd(ivel, na.rm=TRUE)
12
13 # --- 5. Tạo Ma trận thiết kế (Design Matrices) ---
14 # X: Ma trận cho Psi (Intercept + Elev + Forest)
15 X <- cbind(1, elev_z, forest_z)
16
17 # W: Ma trận cho p (Intercept + Ivel). Lưu ý W có 3 chiều (Site x Visit x Covariate)
18 n_sites <- nrow(y)
19 n_visits <- ncol(y)
20 n_cov_p <- 2 # Intercept + Ivel
21
22 W <- array(0, dim = c(n_sites, n_visits, n_cov_p))
23 for(j in 1:n_visits){
24   W[,j,1] <- 1 # Cột 1 là Intercept
25   W[,j,2] <- ivel_z[,j] # Cột 2 là Ivel
26 }
27
28 cat("Dữ liệu đã sẵn sàng!\n")
29 cat("Số địa điểm:", n_sites, "\n")
30 cat("Số lần đo:", n_visits, "\n")

```

Sau khi xử lý xong, số địa điểm còn lại là 191 với 3 lần đo. Tiếp theo, ta sẽ xây dựng Thuật toán MCMC cho mô hình Probit dựa trên phương pháp biến phụ trợ. Về mặt lý thuyết, ta đã xây dựng ở phần trước, tóm gọn cụ thể như sau:

• **Quá trình chiếm cứ:** mô tả trạng thái chiếm cứ thực sự (nhưng không quan sát được) của loài tại địa điểm i . Trong quá trình này sẽ có:

- z_i là biến tiềm ẩn (latent variable) biểu thị trạng thái chiếm cứ tại địa điểm i ($i = 1, \dots, N$) và $z_i \sim \text{Bernoulli}(\psi_i)$
- ψ_i là xác suất chiếm cứ tại địa điểm i với

$$\psi_i = \Phi(\mathbf{x}_i\boldsymbol{\beta}) = \Phi(\beta_0 + \beta_1 \cdot \text{Elevation}_i + \beta_2 \cdot \text{Forest}_i)$$

- Elevation_i : Độ cao đã chuẩn hóa tại điểm i .
- Forest_i : Độ che phủ rừng đã chuẩn hóa tại điểm i .
- $\boldsymbol{\beta}$: Vector các hệ số hồi quy cần ước lượng.

• **Quá trình quan sát:** mô tả dữ liệu quan sát được y_{ij} tại địa điểm i trong lần khảo sát thứ j ($j = 1, \dots, J$). Trong quá trình này sẽ có:

- Dữ liệu quan sát phụ thuộc vào trạng thái thực z_i : $y_{ij}|z_i \sim \text{Bernoulli}(z_i \cdot p_{ij})$
- p_{ij} là xác suất phát hiện loài (với điều kiện loài có mặt) và

$$p_{ij} = \Phi(\mathbf{w}_{ij}\boldsymbol{\alpha}) = \Phi(\alpha_0 + \alpha_1 \cdot \text{Ivel}_{ij})$$

- Ivel_{ij} : Chỉ số nỗ lực/độ dài tuyến khảo sát tại điểm i , lần đo j .
- $\boldsymbol{\alpha}$: Vector các hệ số hồi quy cho quá trình phát hiện.

• **Cấu trúc Biến phụ trợ cho MCMC:** gồm hai biến phụ trợ liên tục v_i và u_{ij} theo đề xuất của Albert & Chib (1993):

$$v_i \sim N(\mathbf{x}_i\boldsymbol{\beta}, 1)$$

$$u_{ij} \sim N(\mathbf{w}_{ij}\boldsymbol{\alpha}, 1)$$

Mối liên hệ với biến nhị phân:

- $z_i = 1$ nếu $v_i > 0$ và $z_i = 0$ nếu $v_i \leq 0$
- $y_{ij} = 1$ nếu $u_{ij} > 0$ và $z_i = 1$

Cấu trúc hàm `occ_probit_mcmc` bao gồm việc cập nhật liên tiếp các tham số như biến phụ trợ, hệ số hồi quy và trạng thái chiếm cứ z , được viết bằng đoạn mã R như sau:

```
1 occ_probit_mcmc <- function(y, X, W, n_iter=100000, burn_in=1000){
2
3   n <- nrow(y)
4   J <- ncol(y)
5
6   # Kích thước tham số
7   k_beta <- ncol(X)
8   k_alpha <- dim(W)[3]
9 }
```



```

10 # Khởi tạo giá trị ban đầu
11 beta <- rep(0, k_beta)
12 alpha <- rep(0, k_alpha)
13 z <- apply(y, 1, max, na.rm=TRUE) # Nếu thấy -> z=1, chưa thấy -> z=0 tạm
14
15 # Lưu kết quả
16 beta_store <- matrix(NA, nrow=n_iter, ncol=k_beta)
17 alpha_store <- matrix(NA, nrow=n_iter, ncol=k_alpha)
18 N_save <- numeric(n_iter)
19
20 # --- BẮT ĐẦU VÒNG LẶP GIBBS ---
21 for(iter in 1:n_iter){
22
23   # 1. Cập nhật Biến phụ trợ v (cho Chiếm cứ)
24   mu_v <- X %*% beta
25   # Nếu z=1: Lấy mẫu v > 0; Nếu z=0: Lấy mẫu v <= 0
26   v <- rtruncnorm(n, a=ifelse(z==1, 0, -Inf), b=ifelse(z==1, Inf, 0), mean=mu_v, sd=1)
27
28   # 2. Cập nhật Beta (Hồi quy tuyến tính trên v)
29   # Prior chuẩn đơn vị: Sigma_beta = I
30   V_beta <- solve(t(X) %*% X + diag(k_beta))
31   m_beta <- V_beta %*% (t(X) %*% v) # Prior mean = 0
32   beta <- c(rmvnorm(1, mean=m_beta, sigma=V_beta))
33
34   # 3. Cập nhật Biến phụ trợ u (cho Phát hiện)
35   # Chỉ cần tính u cho những nơi z=1 (nhưng tính vector hóa hết cho nhanh)
36   W_flat <- matrix(aperm(W, c(2,1,3)), nrow=n*J, ncol=k_alpha) # Biến thành 2D
37   y_vec <- as.vector(t(y))
38   z_long <- rep(z, each=J)
39
40   mu_u <- W_flat %*% alpha
41
42   # Logic:
43   # Nếu y=1 -> u > 0
44   # Nếu y=0 -> u <= 0
45   u_vec <- rtruncnorm(n*J, a=ifelse(y_vec==1, 0, -Inf), b=ifelse(y_vec==1, Inf, 0), mean=mu_u, sd=1)
46
47   # 4. Cập nhật Alpha (Hồi quy tuyến tính trên u)
48   # Chỉ dùng dữ liệu tại những nơi z=1 (con vật có mặt mới có khả năng phát hiện)
49   idx_z1 <- which(z_long == 1)
50   if(length(idx_z1) > 0){
51     W_sub <- W_flat[idx_z1, ]
52     u_sub <- u_vec[idx_z1]
53
54     V_alpha <- solve(t(W_sub) %*% W_sub + diag(k_alpha))
55     m_alpha <- V_alpha %*% (t(W_sub) %*% u_sub)
56     alpha <- c(rmvnorm(1, mean=m_alpha, sigma=V_alpha))
57   }
58
59   # 5. Cập nhật trạng thái z (cho những nơi chưa bao giờ thấy: sum(y)=0)
60   psi_prob <- pnorm(X %*% beta) # Probit link
61   p_prob <- pnorm(array(c(W_flat %*% alpha), dim=c(J, n))) # J x n

```

```

62   q_prob <- 1 - p_prob # Xác suất không thấy
63   prod_q <- apply(q_prob, 2, prod) # Tích xác suất không thấy qua các lần đo
64
65   # Tính xác suất hậu nghiệm Psi_tilde
66   psi_tilde <- (psi_prob * prod_q) / (psi_prob * prod_q + (1 - psi_prob))
67
68   sum_y <- apply(y, 1, sum, na.rm=TRUE)
69   z[sum_y > 0] <- 1 # Chắc chắn có
70   zeros <- which(sum_y == 0)
71   z[zeros] <- rbinom(length(zeros), 1, psi_tilde[zeros])
72
73   # Lưu kết quả
74   beta_store[iter, ] <- beta
75   alpha_store[iter, ] <- alpha
76   N_save[iter] <- sum(z)
77 }
78
79 return(list(beta=beta_store, alpha=alpha_store, N_save = N_save))
80 }

```

Mô hình được chạy với 10000 vòng lặp, loại bỏ 1000 vòng đầu tiên để đảm bảo tính ổn định. Ta sẽ tính toán các giá trị trung bình hậu nghiệm và vẽ biểu đồ minh họa cho phân phối hậu nghiệm và tiên nghiệm như sau:

```

1   # --- Chạy mô hình ---
2   n_iter = 10000
3   set.seed(123)
4   results <- occ_probit_mcmc(y, X, W, n_iter, burn_in=1000)
5   # --- Trục quan hóa kết quả (Bonus Points) ---
6   # Hàm vẽ biểu đồ phân phối hậu nghiệm
7   plot_comparison <- function(samples, name) {
8     # 1. Vẽ Histogram của Hậu nghiệm (Cột màu xanh)
9     hist(samples, freq=FALSE, breaks=40,
10         main = paste("Hậu nghiệm vs. Tiên nghiệm:", name),
11         xlab = "Giá trị tham số", ylab = "Mật độ (Density)",
12         col = "lightblue", border = "white",
13         xlim = c(-1, 1)) # Giới hạn trục x theo chuẩn N(0,1)
14
15     # 2. Vẽ đường mật độ của Hậu nghiệm (Đường xanh đậm)
16     lines(density(samples), col="blue", lwd=2)
17
18     # 3. VẼ TIỀN NGHIỆM (Đường màu đỏ nét đứt) - Đây là cái bạn cần
19     # Tiên nghiệm của mình là N(0, 1)
20     curve(dnorm(x, mean=0, sd=1),
21         col="red", lwd=2, lty=2, add=TRUE) # add=TRUE để vẽ đè lên
22
23     # 4. Thêm chú thích
24     legend("topright", legend=c("Hậu nghiệm (Posterior)", "Tiên nghiệm (Prior)"),
25         col=c("blue", "red"), lty=c(1, 2), lwd=2, bty="n")
26   }
27


```

```


28 par(mfrow=c(1,2)) # Chia khung hình 1x2
29
30 # Beta 1: Tác động của Độ cao
31 plot_comparison(results$beta[-(1:1000), 2], "Beta (Độ cao)")
32 # Beta 2: Tác động của Rừng
33 plot_comparison(results$beta[-(1:1000), 3], "Beta (Rừng)")
34 # Alpha 1: Tác động của Nỗ lực tìm kiếm
35 plot_comparison(results$alpha[-(1:1000), 2], "Alpha (Nỗ lực)")
36
37 # Tính trung bình hậu nghiệm
38 cat("\n--- KẾT QUẢ ƯỚC LƯỢNG ---\n")
39 cat("Beta (Độ cao):", mean(results$beta[-(1:1000), 2]), "\n")
40 cat("Beta (Rừng):", mean(results$beta[-(1:1000), 3]), "\n")
41 cat("Alpha (Nỗ lực):", mean(results$alpha[-(1:1000), 2]), "\n")

```


Ta được kết quả như sau:



Hình 5. Biểu đồ so sánh hậu nghiệm với tiên nghiệm của β_1 (Độ cao)



Hình 6. Biểu đồ so sánh hậu nghiệm với tiên nghiệm của β_2 (Rừng)



Hình 7. Biểu đồ so sánh hậu nghiệm với tiên nghiệm của α_1 (Chỉ số nỗ lực)

```
1 --- KẾT QUẢ ƯỚC LƯỢNG ---
2 Beta (Độ cao): -0.4992328
3 Beta (Rừng): -0.4031382
4 Alpha (Nỗ lực): -0.01742
```

Từ các biểu đồ và số liệu, ta nhận xét:

- Về khả năng chiếm cứ: Cả độ cao và độ che phủ rừng đều có hệ số âm và khoảng tin cậy không chứa số 0. Điều này chỉ ra rằng Vịt cổ xanh có xu hướng tránh các vùng núi cao và các khu vực rừng rậm rạp, phù hợp với đặc tính sinh học của loài thủy cầm này (ưa thích vùng đất ngập nước thoáng đãng ở độ cao thấp).
- Về khả năng phát hiện: Chỉ số nỗ lực (Ivel) có hệ số gần bằng 0 và khoảng tin cậy bao trùm số 0. Điều này cho thấy trong bộ dữ liệu này, sự thay đổi về nỗ lực khảo sát không ảnh hưởng đáng kể đến khả năng phát hiện loài.
- Biểu đồ cho thấy phân phối hậu nghiệm (đường xanh) hẹp và nhọn hơn nhiều so với phân phối tiên nghiệm (đường đỏ), đồng thời tách biệt khỏi giá trị 0 đối với các biến môi trường. Điều này khẳng định dữ liệu cung cấp thông tin mạnh mẽ và đáng tin cậy.

Ngoài ra, mô hình còn cung cấp ước lượng về tổng số địa điểm thực sự có mặt loài Vịt cổ xanh, ta sử dụng đoạn code sau:

```
1 cat("Tổng số địa điểm có vịt ước tính (Mean N):\n")
2 mean(results$N_save[-(1:1000)])
3 cat("\nKhoảng tin cậy 95% của N:\n")
4 quantile(results$N_save[-(1:1000)], c(0.025,0.975))
5 cat("\n Số địa điểm đã tìm thấy vịt theo dữ liệu:\n")
6 sum(apply(y, 1, max, na.rm=TRUE))
```

Kết quả thu được:

```
1 Tổng số địa điểm có vịt ước tính (Mean N):
```

```
2 [1] 40.606
3 Khoảng tin cậy 95% của N:
4 2.5% 97.5%
5 39 44
6 Số địa điểm đã tìm thấy vịt theo dữ liệu:
7 [1] 39
```

Kết quả này cho thấy có khoảng 1-5 địa điểm thực sự có vịt nhưng không được phát hiện trong quá trình khảo sát (False Negatives). Mô hình đã thành công trong việc hiệu chỉnh sai số này.

Như vậy, ta thấy việc ứng dụng mô hình Probit Occupancy sử dụng thuật toán MCMC trên dữ liệu Vịt cổ xanh đã thành công. Thuật toán hoạt động ổn định, hội tụ tốt và đưa ra các kết quả sinh học hợp lý. Phương pháp này chứng minh tính ưu việt trong việc xử lý dữ liệu sinh thái có sai số phát hiện, cung cấp thông tin chính xác hơn cho công tác bảo tồn.

Chương 4

Tổng kết

Đồ án đã xây dựng và kiểm chứng thành công thuật toán MCMC cho mô hình Chiếm cứ (Occupancy Model) sử dụng hàm liên kết Probit, giải quyết hiệu quả bài toán ước lượng phân bố loài trong điều kiện phát hiện không hoàn hảo. Kết quả thực nghiệm trên bộ dữ liệu Vịt cổ xanh (*Anas platyrhynchos*) cho thấy các yếu tố môi trường như độ cao và độ che phủ rừng có tác động tiêu cực mạnh mẽ đến sự hiện diện của loài, trong khi nỗ lực tìm kiếm không ảnh hưởng đáng kể đến khả năng phát hiện trong phạm vi nghiên cứu. Đặc biệt, mô hình đã chứng minh giá trị thực tiễn khi hiệu chỉnh được sai số "âm tính giả" (False Negatives), đưa ra ước lượng số lượng địa điểm chiếm cứ thực tế ($N \approx 41$) cao hơn so với quan sát thô, qua đó cung cấp bức tranh chính xác hơn về hiện trạng phân bố của loài.

Bên cạnh việc khẳng định ưu thế của khung phân tích Bayes trong việc xử lý độ bất định và đưa ra khoảng tin cậy trực quan, nghiên cứu cũng nhận diện một số hạn chế như giả định quần thể đóng và chưa tích hợp yếu tố tương quan không gian giữa các điểm khảo sát. Từ đó, đồ án đề xuất các hướng phát triển tiếp theo bao gồm việc mở rộng sang mô hình chiếm cứ động (Dynamic Occupancy Models) để theo dõi biến động quần thể qua nhiều năm và thử nghiệm các thuật toán tối ưu hơn như Hamiltonian Monte Carlo. Phương pháp này được kỳ vọng sẽ trở thành công cụ đắc lực hỗ trợ công tác giám sát và bảo tồn đa dạng sinh học tại Việt Nam, đặc biệt đối với các loài quý hiếm có dữ liệu quan sát thưa thớt.

Tài liệu tham khảo

- [HH19] Mevin B. Hooten and Trevor J. Hefley. *Bringing Bayesian Models to Life*. CRC Press, Boca Raton, FL, 2019.
- [McInd] James McInerney. Markov Chain Monte Carlo. <https://thetalog.com/statistics/markov-chain-monte-carlo/>, n.d. Truy cập ngày 05/02/2026.
- [Shond] Kevin T. Shoemaker. Occupancy Modeling (nres 746). <https://kevintshoemaker.github.io/NRES-746/Occupancy.html>, n.d. Truy cập ngày 05/02/2026.