

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA TOÁN – TIN HỌC



BÁO CÁO ĐỒ ÁN CUỐI KỲ HỌC PHẦN THỐNG KÊ TRONG SINH HỌC

Đề tài: Phân tích bài báo *Investigating Serum and Tissue Expression Identified a Cytokine/Chemokine Signature as a Highly Effective Melanoma Marker*

Ngành: Toán học

Chuyên ngành: Xác suất - Thống kê

Giảng viên hướng dẫn: TS. Tô Đức Khánh

Sinh viên: Nguyễn Nhật Huy **MSSV:** 23110020

Thành phố Hồ Chí Minh, Ngày 31 tháng 1 năm 2026

Mục lục

Lời nói đầu	3
1 Kiến thức chuẩn bị	5
1.1 Một vài thuật ngữ Y học trong bài	5
1.2 Kiến thức về Thống kê và Phương pháp kiểm định	5
1.3 Nguồn dữ liệu	8
2 Phân tích cụ thể nghiên cứu	9
2.1 Mục tiêu của nghiên cứu	9
2.2 Quy trình thiết kế và thu thập dữ liệu	10
2.3 Phương pháp nghiên cứu	11
2.4 Đánh giá phương pháp	21
3 Đề xuất câu hỏi nghiên cứu	23
3.1 Phân loại Giai đoạn bằng mô hình Phi tuyến	23
3.2 Phân loại Giai đoạn dựa trên tổ hợp 4 gen "chữ ký"	28
4 Mô phỏng lại các phân tích thống kê	33
5 Tổng kết	39
Tài liệu tham khảo	39

Lời nói đầu

Ung thư hắc tố (Melanoma) hiện là một trong những dạng ung thư da có mức độ ác tính và tỷ lệ di căn cao nhất. Việc tìm kiếm các dấu ấn sinh học không xâm lấn để chẩn đoán sớm và tiên lượng giai đoạn bệnh là một nhu cầu cấp thiết của y học hiện đại. Trong bối cảnh đó, bài báo khoa học mang tên **"Cytokines and Chemokines: A New Profile to Predict the Progression of Melanoma?"** đã đặt ra một giả thuyết quan trọng: Liệu hồ sơ nồng độ của các cytokine và chemokine trong cơ thể có thể phản ánh chính xác sự chuyển đổi từ giai đoạn khối u nguyên phát sang di căn hay không? Nghiên cứu này đã sử dụng bộ dữ liệu biểu hiện gen GENT2 để đề xuất các mô hình dự báo dựa trên sự thay đổi miễn dịch.

Đồ án môn học này được thực hiện nhằm mục đích tập trung vào việc tái phân tích và đánh giá lại kết quả của bài báo nói trên dưới góc nhìn của Khoa học Dữ liệu và Thống kê. Cụ thể với vai trò là người phân tích, em đã sử dụng ngôn ngữ lập trình R để kiểm chứng độ tin cậy của các phát hiện trong bài báo gốc thông qua các kiểm định thống kê y sinh (Mann-Whitney U, Kruskal-Wallis). Đồng thời, đồ án mở rộng phạm vi nghiên cứu bằng việc áp dụng các thuật toán học máy tiên tiến hơn như Random Forest để trả lời thêm những câu hỏi có thể được nghiên cứu sâu hơn. Mục tiêu cốt lõi là giải mã các mối quan hệ phi tuyến tính phức tạp giữa các cytokine mà các phương pháp thống kê truyền thống trong bài báo gốc có thể đã bỏ sót, từ đó đưa ra những nhận định khách quan về giá trị thực tiễn của bộ dữ liệu này.

Em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS.Tô Đức Khánh. Thầy đã tận tình hướng dẫn, cung cấp những kiến thức nền tảng quý báu về Thống kê Y sinh và định hướng tư duy phân tích dữ liệu trong suốt quá trình thực hiện đồ án. Đặc biệt, em xin cảm ơn sự hỗ trợ của Thầy trong việc tiếp cận các phương pháp thống kê hiện đại áp dụng cho bộ dữ liệu thực tế. Những lời nhận xét và góp ý của Thầy/Cô không chỉ giúp em hoàn thiện đồ án này mà còn là hành trang kiến thức quan trọng cho em trên con đường nghiên cứu sau này.

Em xin chân thành cảm ơn!

Chương 1

Kiến thức chuẩn bị

1.1 Một vài thuật ngữ Y học trong bài

1.1.1 Ung thư hắc tố (Melanoma)

Ung thư hắc tố (Melanoma) là dạng ung thư da nguy hiểm nhất, phát triển từ các tế bào sản xuất sắc tố da (melanocytes) khi chúng phát triển không kiểm soát. Bệnh thường xuất hiện dưới dạng nốt ruồi mới hoặc thay đổi từ nốt ruồi cũ, có khả năng di căn qua hệ thống máu và bạch huyết đến các cơ quan như phổi, gan và não nếu không được phát hiện và điều trị sớm.

Nguyên nhân chính thường do tiếp xúc quá mức với tia cực tím (UV) từ ánh nắng mặt trời hoặc giường tắm nắng.

Chỉ số Breslow (Độ dày Breslow) là thước đo quan trọng trong ung thư da hắc tố, xác định độ sâu của khối u tính bằng milimét từ bề mặt da đến điểm xâm lấn sâu nhất, giúp tiên lượng mức độ nghiêm trọng của bệnh và phân giai đoạn ung thư, chỉ số càng lớn, khả năng di căn và nguy cơ tiên lượng xấu càng cao.

1.1.2 Dấu ấn sinh học (Biomarkers)

Dấu ấn sinh học có thể được định nghĩa rộng rãi là các thông số có thể định lượng được giúp phân biệt các quá trình bình thường với bệnh lý với các ứng dụng để chẩn đoán, tiên lượng và điều chỉnh điều trị bệnh nhân.

Trong khuôn khổ về Ung thư hắc tố (Melanoma), các dấu ấn sinh học tiên lượng truyền thống bao gồm độ xâm lấn và số lượng phân bào. Các dấu ấn sinh học chẩn đoán và tiên lượng được cải tiến ngày càng quan trọng trong điều trị melanoma với sự phát triển của các liệu pháp mới và nhắm mục tiêu hơn. Do đó bài báo này được tiến hành nhằm mục đích tìm ra những dấu ấn sinh học mới cải thiện những khuyết điểm của các dấu ấn sinh học truyền thống.

1.1.3 Cytokines và Chemokines

Cytokine và chemokine được sử dụng trong nghiên cứu và phát triển để kích hoạt, điều chỉnh và phân hóa tế bào nhằm mục đích hiểu rõ hơn về chức năng của tế bào miễn dịch hoặc tạo ra các liệu pháp dựa trên tế bào. Trong sinh học ung thư hắc tố (Melanoma), chúng kiểm soát một mạng lưới phức tạp bao gồm sự tăng sinh tế bào, phản ứng tạo mạch (angiogenesis) và khả năng di căn của khối u.

1.2 Kiến thức về Thống kê và Phương pháp kiểm định

1.2.1 Kiểm định Mann - Whitney U test

Kiểm định Mann-Whitney U (hay tổng hạng Wilcoxon) là một kiểm định thống kê phi tham số dùng để so sánh sự khác biệt giữa hai nhóm mẫu độc lập khi dữ liệu không tuân theo phân phối chuẩn hoặc dữ liệu ở dạng thứ tự (thứ bậc), thay thế cho t-test độc lập. Nó đánh giá liệu hai nhóm có khả năng đến từ cùng một quần thể bằng cách so sánh thứ hạng (rank) của các giá trị giữa hai nhóm, thay vì

so sánh trực tiếp giá trị trung bình. Lý do chọn kiểm định Mann - Whitney U test cho bài báo này là vì dữ liệu về các loại kiểu gen thường bị lệch (không tuân theo phân phối chuẩn).

1.2.2 Kiểm định ANOVA và Post-hoc Analysis

Phân tích phương sai (ANOVA) là một phép kiểm định thống kê được sử dụng để đánh giá sự khác biệt giữa giá trị trung bình của nhiều hơn hai nhóm. Về bản chất, ANOVA cho phép ta so sánh giá trị trung bình cộng giữa các nhóm cùng một lúc. Từ đó, có thể xác định xem sự khác biệt quan sát được là do ngẫu nhiên hay phản ánh những khác biệt thực sự có ý nghĩa. ANOVA có thể xử lý nhiều yếu tố và sự tương tác giữa chúng, cung cấp một phương pháp mạnh mẽ để hiểu rõ hơn các mối quan hệ phức tạp.

Phân tích hậu kiểm (Post-hoc analysis) đề cập đến một phân tích thống kê được thực hiện sau khi nghiên cứu đã kết thúc và dữ liệu đã được thu thập. Kiểm định hậu kiểm được thực hiện để xác định chính xác nhóm nào khác biệt với nhau. Do đó, các kiểm định như vậy cũng được gọi là kiểm định so sánh đa nhóm.

1.2.3 Phân tích tương quan

Hệ số tương quan Spearman là một thước đo thống kê phi tham số, dùng để đánh giá mức độ mạnh yếu và hướng của mối quan hệ đơn điệu giữa hai biến số dựa trên thứ hạng của chúng, chứ không phải giá trị thực tế, nên nó rất hữu ích cho dữ liệu thứ tự, không tuân theo phân phối chuẩn hoặc có giá trị ngoại lai. Hệ số tương quan hạng Spearman được coi là phiên bản phi tham số của hệ số tương quan tích momen Pearson.

Trong phần phân tích tương quan, ta thường sử dụng các biểu đồ để trực quan hóa mối quan hệ giữa các biến, đặc biệt là Biểu đồ nhiệt (Heatmap).

Biểu đồ nhiệt tương quan là một công cụ đồ họa hiển thị mối tương quan giữa nhiều biến số dưới dạng ma trận mã màu. Nó giống như một bảng màu cho chúng ta thấy các biến số khác nhau có mối liên hệ chặt chẽ như thế nào. Trong biểu đồ nhiệt tương quan, mỗi biến được biểu diễn bằng một hàng và một cột, và các ô thể hiện mối tương quan giữa chúng. Màu sắc của mỗi ô thể hiện độ mạnh và hướng của mối tương quan, với màu tối hơn cho thấy mối tương quan mạnh hơn.


1.2.4 Phân tích thành phần chính (PCA)

Phân tích thành phần chính (PCA) là một kỹ thuật giảm chiều dữ liệu, chuyển đổi một tập dữ liệu thành một tập hợp các thành phần trực giao — được gọi là các thành phần chính — nắm bắt được phương sai tối đa trong dữ liệu. PCA đơn giản hóa các tập dữ liệu phức tạp trong khi vẫn bảo toàn các cấu trúc quan trọng nhất của chúng.

Các thành phần chính là các biến mới được xây dựng dưới dạng tổ hợp tuyến tính hoặc hỗn hợp của các biến ban đầu. Các tổ hợp này được thực hiện theo cách sao cho các biến mới (tức là các thành phần chính) không tương quan và hầu hết thông tin trong các biến ban đầu được nén lại vào thành phần đầu tiên.


1.2.5 Phân tích ROC & chỉ số AUC

Đường cong ROC là hình ảnh trực quan về hiệu suất của mô hình trên tất cả các ngưỡng. Đường cong ROC được vẽ bằng cách tính tỷ lệ dương tính thực (TPR) và tỷ lệ dương tính giả (FPR) ở mọi ngưỡng có thể (trong thực tế, ở các khoảng thời gian đã chọn), sau đó lập biểu đồ TPR trên FPR. Một mô hình hoàn hảo, ở một ngưỡng nào đó có TPR là 1.0 và FPR là 0.0, có thể được biểu thị bằng một điểm tại (0, 1) nếu tất cả các ngưỡng khác bị bỏ qua.



Hình 1. ROC và AUC của một mô hình hoàn hảo giả định.


Diện tích dưới đường cong ROC (AUC) là một giá trị vô hướng duy nhất nằm trong khoảng từ 0 đến 1, cho biết hiệu suất của mô hình. Ta chỉ tính toán được AUC sau khi tạo đường cong ROC vì AUC thể hiện diện tích bên dưới đường cong. AUC là một chỉ số hữu ích để so sánh hiệu suất của hai mô hình khác nhau, miễn là tập dữ liệu được cân bằng gần như nhau. Mô hình có diện tích lớn hơn dưới đường cong thường là mô hình tốt hơn.



Hình 2. Chỉ số AUC của một mô hình giả định.

1.2.6 Các kỹ thuật học máy cơ bản (Machine Learning)

Support Vector Machine (SVM) là một thuật toán học có giám sát được ứng dụng để xử lý tín hiệu, y tế, xử lý ngôn ngữ tự nhiên, nhận dạng giọng nói và hình ảnh, được sử dụng rộng rãi trong các bài toán phân loại và hồi quy. Mục tiêu của thuật toán SVM là tìm ra một siêu phẳng (hyperplane) sao cho có thể phân tách tối ưu các điểm dữ liệu thuộc hai lớp khác nhau. “Tối ưu” ở đây nghĩa là tìm siêu phẳng tạo ra khoảng cách lớn nhất (margin) giữa hai lớp dữ liệu. Trong nghiên cứu này, SVM được sử dụng để phân loại bệnh nhân (ung thư và bình thường) dựa trên tổ hợp 27 Cytokines/Chemokines.



Hình 3. Hình ảnh minh họa cho SVM

Phương pháp loại bỏ biến đệ quy (Recursive Feature Elimination - RFE) là một phương pháp hiệu quả để loại bỏ các biến khỏi tập dữ liệu huấn luyện nhằm mục đích chọn lọc những biến tốt nhất. RFE hoạt động bằng cách tìm kiếm một tập hợp con các biến, bắt đầu với tất cả các biến trong tập dữ liệu huấn luyện và loại bỏ dần các biến cho đến khi số lượng còn lại đạt mức mong muốn. Trong khuôn khổ nghiên cứu này, RFE được sử dụng để chọn lọc các Cytokines có ý nghĩa quan trọng và có tiềm năng chẩn đoán.

K-fold cross-validation là kỹ thuật đánh giá hiệu suất mô hình học máy bằng cách chia ngẫu nhiên dữ liệu thành k phần (folds) bằng nhau. Mô hình được huấn luyện k lần, mỗi lần sử dụng $k - 1$ phần để huấn luyện và phần còn lại để kiểm thử, sau đó lấy trung bình kết quả, giúp đánh giá chính xác và chống quá khớp (overfitting). Trong bài nghiên cứu này, nhóm nghiên cứu sử dụng kiểm chứng chéo 10 lần (10-fold cross-validation) để đánh giá khách quan hiệu năng của mô hình SVM.

1.3 Nguồn dữ liệu

GENT2 Database: Đây là cơ sở dữ liệu công cộng chứa dữ liệu dùng để khám phá các mẫu biểu hiện gen trên nhiều mô bình thường và mô khối u khác nhau ở người.

Chương 2

Phân tích cụ thể nghiên cứu

Chương này tập trung phân tích chi tiết cấu trúc thực hiện của bài báo, bắt đầu từ việc chuyển hóa các vấn đề y sinh về ung thư hắc tố thành câu hỏi thống kê cụ thể, mô tả quy trình thu thập dữ liệu song song trên huyết thanh và mô, đồng thời đánh giá tính hiệu quả của các phương pháp kiểm định và mô hình máy học được sử dụng để xác định bộ dấu ấn sinh học tiềm năng.

2.1 Mục tiêu của nghiên cứu

Mục tiêu của nghiên cứu này là xác định các dấu ấn sinh học hiệu quả bằng cách điều tra biểu hiện của 27 loại cytokine/chemokine ở ung thư hắc tố so với đối chứng khỏe mạnh, cả trong mẫu huyết thanh và mẫu mô. Xuất phát từ mục tiêu nghiên cứu này, nhóm nghiên cứu đã đặt ra những câu hỏi nghiên cứu về Sinh học/ Y tế, cũng như là những câu hỏi về mặt Thống kê tương ứng. Một số câu hỏi cốt lõi của bài nghiên cứu sẽ được liệt kê dưới đây.

2.1.1 Câu hỏi Sinh học/ Y tế

Câu hỏi 1: Mức độ biểu hiện của 27 loại cytokine và chemokine trong huyết thanh (serum) và mô (tissue) có sự khác biệt giữa bệnh nhân ung thư hắc tố và người khỏe mạnh không?

- Căn cứ vào trích dẫn từ phần Abstract của bài báo: *"The aim of the present study was to identify effective biomarkers by investigating the expression of 27 cytokines/chemokines in melanoma compared to healthy controls, both in serum and in tissue samples."* Trả lời được câu hỏi này, nhóm tác giả sẽ nhận ra những điểm khác biệt quan trọng về biểu hiện gen giữa nhóm bệnh nhân ung thư và người khỏe mạnh, từ đó tìm ra được một dấu ấn sinh học phù hợp tốt cho việc chẩn đoán.

Câu hỏi 2: Liệu các cytokine/chemokine này (đơn lẻ hoặc kết hợp) có thể đóng vai trò là dấu ấn sinh học (biomarkers) tin cậy để chẩn đoán sớm ung thư hắc tố không?

- Căn cứ vào trích dẫn từ phần Simple Summary của bài báo: *"From the gene expression analysis, we identified several cytokines/chemokines showing strongly different expression in melanoma as compared to the controls, and the 4-gene signature "IL-1Ra, IL-7, MIP-1a, and MIP-1b" as the best combination to discriminate melanoma samples from the controls, with an extremely high accuracy (AUC = 0.98). These data indicate the molecular mechanisms underlying melanoma setup and the relevant markers potentially useful to help the diagnosis of biopsy samples."* Từ việc phân tích gen, tác giả muốn tìm ra một dấu ấn sinh học giúp ích cho việc chẩn đoán (trên thực tế đã tìm được trong bài nghiên cứu).

Câu hỏi 3: Các yếu tố lâm sàng như tuổi tác, giới tính và độ dày khối u (Breslow thickness) có ảnh hưởng đến mức độ biểu hiện của các cytokine này trong huyết thanh không?

- Căn cứ vào trích dẫn từ phần Simple Summary của bài báo: *"It identified several cytokines/chemokines differently expressed in melanoma patients as compared to the healthy controls, as a function of the presence of the melanoma, age, tumor thickness, and gender, indicating different systemic responses to the melanoma presence."* Với việc đặt ra câu hỏi này, nhóm nghiên cứu mong muốn xác định sự ảnh hưởng của các yếu tố tuổi, giới, độ dày của khối u đến biểu hiện của các cytokine trong huyết

thanh, điều này sẽ giúp các nhà nghiên cứu y học lựa chọn phương pháp chẩn đoán, chữa bệnh đối với từng nhóm tuổi hoặc giới.

2.1.2 Câu hỏi Thống kê

Từ các câu hỏi Sinh học/ Y tế ở trên, ta cũng có những câu hỏi về mặt thống kê tương ứng.

- **Câu hỏi 1:** Có sự khác biệt có ý nghĩa thống kê về giá trị trung vị về nồng độ/biểu hiện của các cytokine giữa nhóm bệnh và nhóm đối chứng không?
- **Câu hỏi 2:** Biến số nào (hoặc tổ hợp biến số nào) mang lại độ chính xác phân loại cao nhất, được đo lường bằng Diện tích dưới đường cong ROC (AUC)?
- **Câu hỏi 3:** Có sự tương quan tuyến tính đáng kể giữa các cặp cytokine trong nhóm bệnh nhân ung thư so với nhóm người khỏe mạnh không?
- **Câu hỏi 4:** Có sự khác biệt có ý nghĩa thống kê về giá trị trung vị (median) nồng độ/biểu hiện của các cytokine trong huyết thanh giữa các độ tuổi/ giới tính trong nhóm bệnh nhân hay không?

Đó là những câu hỏi cốt lõi mà nhóm tác giả muốn tìm ra đáp án để đạt được mục tiêu của nghiên cứu. Trong khuôn khổ môn học, chúng ta sẽ tập trung trả lời các câu hỏi liên quan đến Thống kê.

2.2 Quy trình thiết kế và thu thập dữ liệu

Nghiên cứu này được thiết kế theo dạng nghiên cứu bệnh - chứng (Case-Control Study) và kết hợp với phân tích dữ liệu thứ cấp từ các nguồn công khai, thực hiện trên hai bộ dữ liệu độc lập: Huyết thanh và Mô. Để dễ theo dõi, ta sẽ chia nghiên cứu này thành 2 giai đoạn: Phân tích trên Huyết thanh và Phân tích trên Mô. Quy trình thiết kế và thu thập dữ liệu được trình bày khái quát trong mục **2.1** của bài báo (Study Workflow) và trình bày cụ thể chi tiết trong mục **4. Materials and Methods**.

2.2.1 Giai đoạn 1: Nghiên cứu trên huyết thanh (Serum)

Đối tượng nghiên cứu: Bệnh nhân u ác tính liên tục được tuyển dụng tại các khoa bệnh viện của IDI-IRCCS (Ý), dựa trên một tổn thương da nghi ngờ. Ngoài ra, nghiên cứu có đi kèm một tiêu chuẩn loại trừ: Loại bỏ các bệnh nhân đang điều trị thuốc chống ung thư tại thời điểm lấy mẫu.

Cỡ mẫu: Tổng cộng 232 mẫu (96 ca bệnh và 136 ca chứng). Trong đó:

- **Nhóm bệnh (Cases):** 96 bệnh nhân được chẩn đoán xác định là U hắc tố (Melanoma) qua kết quả mô bệnh học.
- **Nhóm chứng (Controls):** 136 bệnh nhân có tổn thương da nghi ngờ nhưng kết quả mô bệnh học xác định không phải là Melanoma (Non-melanoma suspect lesions).

Quy trình thu thập và xử lý mẫu:

- Tổng cộng 7 mL máu ngoại vi được thu thập từ bệnh nhân trước khi bệnh nhân làm sinh thiết. Máu được thu thập trong các ống không có bất kỳ loại chất phụ gia nào. Các ống được lấy ở nhiệt độ phòng trong 2 đến 3 giờ; sau đó chúng được ly tâm ở tốc độ 15.000 vòng/phút trong 15 phút; huyết thanh màu vàng trong được bảo quản trong các phần 100 μ L và được bảo quản ở -80° C. Máu đỏ được coi là dấu hiệu tan máu và huyết thanh như vậy sẽ không được phân tích trong nghiên cứu hiện tại.

- Sau đó sử dụng công nghệ xMAP trên nền tảng Luminex (Bio-Plex Pro human cytokine 27-plex panel, Bio-Rad) để phân tích định lượng. Đây là kỹ thuật cho phép đo nồng độ của nhiều chất cùng lúc trong một mẫu nhỏ.

Các biến quan sát:

- Biến phụ thuộc: Chẩn đoán tình trạng bệnh (Melanoma vs Control).
- Biến độc lập: Nồng độ của 27 loại Cytokines/Chemokines (đơn vị: pg/mL).
- Biến nhân khẩu/Lâm sàng: Tuổi, Giới tính, Chỉ số độ sâu khối u Breslow (Breslow's thickness).

2.2.2 Giai đoạn 2: Nghiên cứu trên Mô (Tissue)

Nguồn dữ liệu: Dữ liệu được trích xuất từ cơ sở dữ liệu GENT2 (Gene Expression Database of Normal and Tumor Tissues 2). Các mẫu này có nguồn gốc từ dữ liệu biểu hiện gen (transcriptomic data) của nền tảng NCBI GEO (Gene Expression Omnibus).

Cỡ mẫu: Tổng cộng 511 mẫu. Trong đó:

- **Nhóm chứng (Normal skin):** 201 mẫu sinh thiết da thường (từ 11 nghiên cứu độc lập).
- **Nhóm U nguyên phát (Primary Melanoma):** 83 mẫu (từ 4 nghiên cứu độc lập).
- **Nhóm U di căn (Metastatic Melanoma):** 227 mẫu (từ 11 nghiên cứu độc lập).

Cách thức thu thập dữ liệu:

- Nhóm nghiên cứu truy cập cơ sở dữ liệu GENT2, lọc lấy các bộ dữ liệu liên quan đến "Skin" và "Melanoma".
- Tải xuống dữ liệu biểu hiện gen (Gene Expression Profiling) tương ứng với 27 loại cytokine/chemokine đã phân tích ở phần huyết thanh để đối chiếu.

Các biến quan sát:

- Mức độ biểu hiện gen của 27 loại Cytokines/Chemokines tương ứng.
- Thông tin phân loại: Da thường, U nguyên phát, U di căn.
- Thông tin sống còn (Survival data): Dùng cho phân phân tích tiên lượng (mục 2.7).

2.3 Phương pháp nghiên cứu

Toàn bộ các phân tích thống kê trong nghiên cứu này được thực hiện bằng phần mềm R (phiên bản 4.0.0). Các phương pháp cụ thể được áp dụng để giải quyết từng câu hỏi nghiên cứu bao gồm:

2.3.1 Phân tích đơn biến (Single - Molecule Analysis)

Để so sánh nồng độ của từng loại cytokine/chemokine riêng lẻ giữa các nhóm, nghiên cứu sử dụng các kiểm định sau:

- **Kiểm định Mann–Whitney (Mann–Whitney U test):** Được sử dụng để so sánh trung vị (median) giữa hai nhóm độc lập (Nhóm bệnh vs. Nhóm chứng) do dữ liệu không tuân theo phân phối chuẩn. Kết quả được hiệu chỉnh bằng phương pháp Bonferroni để kiểm soát sai số khi thực hiện nhiều phép kiểm định cùng lúc. Cụ thể, kiểm định đã được sử dụng trong mục **2.1**, *Table 2* và kết quả được in ra như sau:

Table 2. Serum expression. Medians of the expression values of the 27 cytokines/chemokines for the control and melanoma patients. The table also reports the significance of the differences according to Mann–Whitney analyses. For p -values < 0.05 , the null hypothesis that the control and melanoma patients have the same median should be rejected (significant values reported in bold and are underlined); i.e., a $p < 0.05$ indicates a significant difference. Moreover, the table reports the classification performances as the AUC values from the ROC analyses.

Cytokines	Controls Median ($n = 136$)	Melanoma Median ($n = 96$)	p -Value Mann–Whitney Controls vs. Melanoma	AUC $\pm$ S.E. by ROC Analysis
IL-1b	0.53	0.65	<u>0.04</u>	0.61 $\pm$ 0.05
IL-1Ra	26.77	17.83	0.14	0.56 $\pm$ 0.04
IL-2	3.45	2.14	0.14	0.66 $\pm$ 0.10
IL-4	2.95	2.88	0.47	0.53 $\pm$ 0.04
IL-5	2.77	2.34	0.22	0.60 $\pm$ 0.08
IL-6	5.37	3.17	<u>0.04</u>	0.70 $\pm$ 0.09
IL-7	2.24	2.24	0.72	0.52 $\pm$ 0.05
IL-8	6.63	6.4	0.55	0.52 $\pm$ 0.04
IL-9	45.58	42.05	0.29	0.54 $\pm$ 0.04
IL-10	7.08	4.56	0.10	0.63 $\pm$ 0.08
IL-12(p70)	15.74	16.07	1.00	0.50 $\pm$ 0.05
IL-13	2.43	2.99	0.83	0.52 $\pm$ 0.09
IL-15	52.22	30.11	1.00	0.50 $\pm$ 0.27
IL-17	16.72	13.1	0.37	0.54 $\pm$ 0.04
Eotaxin	95.28	106.28	0.38	0.53 $\pm$ 0.04
FGF-2	32.68	30.01	0.26	0.55 $\pm$ 0.04
G-CSF	4.73	5.41	0.33	0.55 $\pm$ 0.05
GM-CSF	10.21	10.63	0.67	0.53 $\pm$ 0.06
IFN- γ	19.1	23.2	0.48	0.53 $\pm$ 0.04
IP-10 (CXCL10)	438.69	501.41	<u>0.04</u>	0.58 $\pm$ 0.04
MCP-1(MCAF)	18.59	12.49	0.24	0.58 $\pm$ 0.07
MIP-1a (CCL3)	1.78	1.74	0.59	0.52 $\pm$ 0.04
MIP-1b (CCL4)	54.36	56.26	0.43	0.53 $\pm$ 0.04
PDGF-BB	1603.74	1033.41	<u>0.01</u>	0.61 $\pm$ 0.05
RANTES (CCL5)	11,353.34	8735.27	<u>0.01</u>	0.57 $\pm$ 0.06
TNF- α	16.4	18.06	0.26	0.52 $\pm$ 0.06
VEGF	59.75	57.98	0.88	0.54 $\pm$ 0.06

Bold underlined: highlight the result.

Hình 4. Bảng kết quả của kiểm định Mann-Whitney cho sự khác biệt giữa Giá trị trung vị về nồng độ Cytokine của nhóm Bệnh nhân và nhóm Đối chứng

Từ bảng kết quả, ta thấy sự khác biệt về giá trị trung vị của một số phân tử Cytokines như IL-1b, IL-6, IP-10, PDGF-BB và RANTES giữa nhóm Bệnh nhân và nhóm Đối chứng là có ý nghĩa thống kê.

Ngoài ra, kiểm định Mann-Whitney cũng được sử dụng để so sánh sự khác biệt về nồng độ cytokine giữa hai nhóm giới tính: Nam (Male Melanoma) và Nữ (Female Melanoma), kết quả được in ra trong bảng *Table 6* của bài báo cáo, cụ thể như sau:

Table 6. Serum expression in male melanoma compared to female melanoma. For p -values < 0.05 (reported in bold and underlined), the null hypothesis (i.e., the two distributions have the same median) should be rejected. Briefly, the cytokine distributions for the control and melanoma patients with p -values < 0.05 have significantly different medians.

Cytokines	Male Melanoma	Female Melanoma	Mann-Whitney
	Median Value	Median Value	p -Value
IL-1b	0.63	0.785	0.07
IL-1Ra	15.17	24.125	0.25
IL-2	1.9	3.09	0.14
IL-4	3.05	2.75	0.06
IL-5	2.34	2.02	0.36
IL-6	3.34	3.0	0.73
IL-7	2.24	2.31	0.49
IL-8	6.57	6.32	0.64
IL-9	44.35	38.84	0.14
IL-10	3.84	6.31	0.13
IL-12(p70)	16.94	14.57	0.98
IL-13	2.19	3.23	0.60
IL-15	-	30.11	-
IL-17	13.1	12.96	0.67
Eotaxin	135.15	91.8	<u>0.002</u>
FGF-2	32.55	29.73	0.25
G-CSF	5.09	5.45	0.60
GM-CSF	11.71	9.97	0.47
IFN- γ	20.83	27.33	0.26
IP-10 (CXCL10)	567.19	468.93	0.13
MCP-1(MCAF)	10.995	25.6	<u>0.05</u>
MIP-1a (CCL3)	1.86	1.7	0.49
MIP-1b (CCL4)	56.89	51.09	0.30
PDGF-BB	1145.64	900.76	0.06
RANTES (CCL5)	9536.67	7879.5	0.19
TNF- α	17.355	20.11	0.34
VEGF	65.345	50.515	0.49

Bold underlined: highlight the result.

Hình 5. Bảng kết quả của kiểm định Mann-Whitney cho sự khác biệt giữa về nồng độ cytokine giữa hai nhóm bệnh nhân chia theo giới tính

Ngoài ra, kiểm định Mann-Whitney còn được sử dụng để so sánh sự khác biệt về nồng độ cytokine giữa 2 nhóm bệnh nhân được chia theo độ dày Breslow ($>1\text{mm}$ và $<1\text{mm}$), kết quả cụ thể ở trong Table 3, tương tự cho table 8 của bài báo cáo.

- **Kiểm định ANOVA:** Được sử dụng khi so sánh giữa 3 nhóm (Da thường, U nguyên phát, U di căn) trong giai đoạn phân tích Mô. Vì việc sử dụng ANOVA yêu cầu về một vài giả định của dữ liệu, nên bài nghiên cứu cũng đã sử dụng kiểm định Shapiro-Wilk để kiểm tra tính chuẩn (normality) và kiểm định Levene để kiểm tra tính đồng nhất của phương sai (homoscedasticity). Sau đó, nếu ANOVA cho kết quả có ý nghĩa, sử dụng kiểm định hậu kiểm (Post-hoc) Tukey's HSD để xác định cụ thể cặp nhóm nào khác biệt nhau. Cụ thể được trình bày trong bảng Table S6 trong bài nghiên

cứu như sau:

Table S6. Anova analysis of tissue expression data.

Cytokines	Normality assesment			Homogen. variances	Anova P value	Post hoc tests		
	Ctrls	Primary	Metast.			Ctrls vs. Primary	Ctrls vs. Metast.	Primary vs. Metast.
<i>IL-1b</i>	N	N	N	N	0.02	0.15	<u><0.0001</u>	0.71
<i>IL-1Ra</i>	N	Y	N	N	<u><0.0001</u>	<u><0.0001</u>	<u><0.0001</u>	1.31
<i>IL-2</i>	N	N	N	Y	0.61	-	-	-
<i>IL-4</i>	N	N	N	Y	0.14	-	-	-
<i>IL-5</i>	N	Y	N	Y	0.74	-	-	-
<i>IL-6</i>	N	Y	Y	N	<u><0.0001</u>	0.06	<u><0.0001</u>	0.06
<i>IL-7</i>	N	Y	N	N	<u><0.0001</u>	<u><0.0001</u>	<u><0.0001</u>	<u>0.01</u>
<i>IL-8</i>	N	N	N	N	0.92	-	-	-
<i>IL-9</i>	N	Y	N	Y	0.33	-	-	-
<i>IL-10</i>	Y	Y	N	Y	<u><0.0001</u>	<u>0.0004</u>	<u><0.0001</u>	0.43
<i>IL-12(p70)</i>	N	N	N	N	<u><0.0001</u>	<u><0.0001</u>	<u><0.0001</u>	0.12
<i>IL-13</i>	N	N	N	N	0.56	-	-	-
<i>IL-15</i>	N	Y	Y	N	<u><0.0001</u>	<u>0.001</u>	1.00	<u>0.01</u>
<i>IL-17</i>	N	N	N	N	<u><0.0001</u>	0.08	<u><0.0001</u>	<u>0.05</u>
<i>Eotaxin</i>	N	Y	N	Y	<u><0.0001</u>	0.18	<u><0.0001</u>	0.06
<i>FGF-2</i>	N	Y	Y	N	<u>0.005</u>	<u><0.0001</u>	0.53	<u><0.0001</u>
<i>G-CSF</i>	N	N	N	N	<u><0.0001</u>	<u>0.001</u>	0.30	<u>0.006</u>
<i>GM-CSF</i>	N	Y	N	Y	0.61	-	-	-
<i>IFN-γ</i>	N	N	N	N	<u><0.0001</u>	<u>0.03</u>	<u><0.0001</u>	<u>0.01</u>
<i>IP-10 (CXCL10)</i>	N	N	N	N	<u><0.0001</u>	0.36	<u><0.0001</u>	<u>0.01</u>
<i>MCP-1(MCAF)</i>	N	Y	N	Y	<u>0.0005</u>	0.63	<u>0.003</u>	<u>0.003</u>
<i>MIP-1a (CCL3)</i>	N	Y	N	Y	<u><0.0001</u>	<u><0.0001</u>	<u><0.0001</u>	0.07
<i>MIP-1b (CCL4)</i>	N	Y	N	N	<u><0.0001</u>	<u><0.0001</u>	<u><0.0001</u>	0.12
<i>PDGF-BB</i>	N	N	N	N	<u>0.007</u>	0.60	<u>0.001</u>	<u>0.003</u>
<i>RANTES (CCL5)</i>	N	Y	N	N	<u><0.0001</u>	<u><0.0001</u>	<u><0.0001</u>	1.00
<i>TNF-α</i>	N	Y	N	N	<u><0.0001</u>	<u><0.0001</u>	<u><0.0001</u>	<u>0.003</u>
<i>VEGF</i>	N	N	N	N	0.08	-	-	-

Hình 6. Bảng kết quả phân tích ANOVA dữ liệu biểu hiện mô.

Từ bảng kết quả, ta thấy được rằng:

- *Controls vs. Primary/Metastatic*: Hầu hết p-value đều < 0.0001 . Điều này cho thấy có sự khác biệt về biểu hiện mô trong 27 cytokine giữa nhóm Đối chứng và nhóm Bệnh nhân, chứng tỏ xác nhận các cytokine này phân biệt tốt giữa "Lành" và "Ác".
- *Primary vs. Metastatic*: Cột cuối cùng cho thấy rất ít chất có p-value < 0.05 . Điều này xác nhận kết luận trong bài: Các dấu ấn này không phân biệt tốt giữa giai đoạn sớm và giai đoạn di căn (trừ một vài ngoại lệ như IL-7, TNF-alpha).

2.3.2 Phân tích tương quan (Paired-Molecule Analysis)

Để đánh giá mối liên hệ giữa các cytokine với nhau, nhóm nghiên cứu đã Sử dụng Hệ số tương quan thứ hạng Spearman (Spearman's rank correlation coefficient). Phương pháp này giúp xây dựng ma trận tương quan và phát hiện sự thay đổi trong mạng lưới liên kết của các chất khi chuyển từ trạng thái khỏe mạnh sang ung thư. Ví dụ như trong *Table 4*, Tương quan Spearman đã được sử dụng để xem xét mối liên hệ liên tục giữa Nồng độ cytokine và Độ dày Breslow (mm).

Table 4. Serum expression in all melanoma patients (male + female): correlation with Breslow thickness. For p -values < 0.05 (reported in bold and underlined), the null hypothesis (i.e., the Spearman's correlation coefficient R is 0) should be rejected; i.e., cytokine distributions with p -values < 0.05 are significantly correlated with Breslow thickness.

Cytokines	No. of Pairs	Spearman R Correlation of Serum Expression with Breslow Thickness	p -Value (2-Tails)
IL-1b	42	0.04	0.80
IL-1Ra	71	0.04	0.75
IL-2	12	0.01	0.97
IL-4	89	-0.02	0.88
IL-5	24	0.01	0.96
IL-6	15	0.24	0.40
IL-7	46	0.28	0.06
IL-8	77	-0.23	<u>0.05</u>
IL-9	87	-0.09	0.42
IL-10	21	-0.14	0.55
IL-12(p70)	60	-0.02	0.86
IL-13	19	-0.09	0.72
IL-15	3	1.00	0.33
IL-17	68	0.05	0.67
Eotaxin	89	-0.01	0.96
FGF-2	83	0.03	0.81
G-CSF	37	0.04	0.83
GM-CSF	42	-0.40	<u>0.01</u>
IFN- γ	82	0.07	0.53
IP-10 (CXCL10)	88	0.04	0.72
MCP-1(MCAF)	29	0.39	<u>0.04</u>
MIP-1a (CCL3)	89	-0.09	0.40
MIP-1b (CCL4)	88	-0.02	0.86
PDGF-BB	88	-0.10	0.35
RANTES (CCL5)	88	-0.20	0.06
TNF- α	62	0.31	<u>0.01</u>
VEGF	86	-0.02	0.87

Bold underlined: highlight the result.

Hình 7. Bảng kết quả thể hiện mối tương quan giữa Nồng độ Cytokine trong Huyết thanh và Độ dày Breslow

Ngoài ra, Tương quan Spearman cũng được sử dụng để phân tích mối liên hệ giữa các Cytokine với nhau, kết quả cụ thể trong *Figure 2* và *Figure 3* như sau:




Figure 2. Correlation analysis of the serum expression values. The heatmaps in (A,B) show the correlation of pairs of expression values having a p -value <0.05 and Spearman's rank coefficient >0.60 , in the control and in melanoma samples, respectively.

Hình 8. Phân tích tương quan của các giá trị biểu hiện huyết thanh.




Figure 3. Correlation analysis of the serum expression values of all the control (A) and melanoma (B) samples. The connected circles show the paired molecules having $p < 0.05$ and Spearman's R coefficient >0.70 , in the control and melanoma samples, respectively. The correlations specifically present in the melanoma samples are highlighted with blue dashed lines.

Hình 9. Phân tích tương quan của các giá trị biểu hiện huyết thanh. Các mối tương quan đặc biệt hiện diện trong các mẫu u ác tính được đánh dấu bằng các đường đứt nét màu xanh lam.

2 hình trên minh họa sự thay đổi cấu trúc mạng lưới cytokine trong bệnh lý Melanoma. Kết quả cho thấy ở bệnh nhân ung thư, các phân tử không còn hoạt động độc lập như ở người khỏe mạnh mà hình thành các cụm tương quan chặt chẽ (thể hiện qua mật độ kết nối dày đặc hơn). Điều này phản ánh phản ứng miễn dịch và viêm có tính hệ thống của cơ thể đối với khối u.

2.3.3 Phân tích hồ sơ đa biến (Profile Analysis) và Học máy (Machine Learning)

Phương pháp học máy SVM được triển khai qua hai giai đoạn thử nghiệm. Giai đoạn 1 (được trình bày ở mục 2.3) áp dụng trên dữ liệu huyết thanh để đánh giá tiềm năng chẩn đoán sơ bộ. Giai đoạn 2 (được trình bày ở mục 2.6) áp dụng trên dữ liệu mô, kết hợp với thuật toán loại bỏ biến đệ quy (RFE) để tối ưu hóa mô hình và xác định bộ dấu ấn sinh học cốt lõi (biomarker signature).

- **Giai đoạn 1 (áp dụng trên dữ liệu huyết thanh):** Sau khi thấy các cytokine trong máu (IL-6, IL-8,...) đứng một mình (mục 2.1) có độ chính xác quá thấp ($AUC < 0.70$), nhóm tác giả đã dùng SVM để gom tất cả lại. Nhóm nghiên cứu đã đưa toàn bộ 27 Cytokines vào mô hình SVM, sau đó sử dụng kỹ thuật 10-fold cross-validation để kiểm tra. Với những dữ liệu thiếu, nhóm nghiên cứu đã thử nghiệm xử lý bằng 2 cách: Gán bằng 0 hoặc loại bỏ mẫu. Kết quả được trình bày cụ thể trong **Table 7** như sau:

Table 7. Results of the SVM method applied to the serum expression dataset. Missing values are either removed or assigned as zero. In the first case, some molecules are removed from the predictor values (remaining molecules are listed in the “Molecules” column). Sex and/or age are or are not regarded as predictors. The p -value is the probability that the “Accuracy” value is not significantly above the “No Info Rate” value.

Missing Values	Num. Melanoma	Num. Controls	Training Set Size	Testing Set Size	Predictors: Sex or Age	AUC (ROC)	Accuracy	No Info Rate	p -Value
Removed *	72	124	138	58	Sex, Age	0.674	0.621	0.64	0.66
					Sex	0.658	0.638	0.64	0.56
					Age	0.761	0.724	0.64	0.11
					None	0.615	0.586	0.64	0.83
Set to 0 **	96	136	164	68	Sex, Age	0.621	0.588	0.59	0.55
					Sex	0.510	0.588	0.59	0.55
					Age	0.704	0.662	0.59	0.13
					None	0.619	0.588	0.59	0.55

* When the missing values were removed, IL-4, IL-8, IL-9, Eotaxin, FGF-2, IFN- γ , IP-10, MIP-1a, MIP-1b, PDGF-BB, RANTES, and VEGF were simultaneously analyzed by the SVM. ** When the missing values were set to 0, all 27 cytokines/chemokines were simultaneously analyzed by SVM.

Hình 10. Kết quả của phương pháp SVM áp dụng cho tập dữ liệu huyết thanh.

Kết quả là chỉ số AUC được cải thiện lên 0.761 với p -value = 0.11, từ đó tác giả đã kết luận rằng có cải thiện nhưng vẫn chưa đủ tốt để dùng làm xét nghiệm chẩn đoán lâm sàng.

- **Giai đoạn 2 (áp dụng trên dữ liệu mô):** Rút kinh nghiệm từ huyết thanh, tác giả áp dụng quy trình tương tự lên mô sinh thiết, nhưng ở mức độ cao cấp hơn. Ngoài việc chạy SVM đơn thuần, họ còn kết hợp với kỹ thuật RFE (Recursive Feature Elimination), một kỹ thuật dùng để lọc chất. Với kỹ thuật RFE, máy tính sẽ chạy thử 27 chất, sau đó bỏ bớt chất kém nhất, chạy lại với 26 chất,... cứ thế lặp lại để tìm ra tổ hợp nhỏ nhất nhưng hiệu quả nhất. Kết quả được trình bày cụ thể trong *Table 10* như sau:

Table 10. SVM method applied to the tissue-expression dataset. Sex and age were not considered as predictors for the lack of data in the dataset. The p , i.e., the probability that the "Accuracy" value is not significantly higher than the "No Info Rate" value, is lower than 0.00001. Hence, we can safely reject the null hypothesis and we can assume that the accuracy of the predictive model is higher than the value of the No Info Rate (0.61), corresponding to the performance of a dummy, fixed-answer predictor.

Num. Melanoma	Num. Controls	Training Set Size	Testing Set Size	AUC (ROC)	Accuracy	No Info Rate	p -Value
310	201	358	153	0.99	0.95	0.61	<0.00001

Hình 11. Kết quả của phương pháp SVM áp dụng cho tập dữ liệu mô.

Ta thấy với việc sử dụng thuật toán SVM kết hợp kỹ thuật RFE, nhóm nghiên cứu đã thành công đưa độ chính xác lên 95% và AUC đạt 0.99. Một minh họa về AUC cũng được đưa ra trong *Figure 7* như sau:




Figure 7. ROC analysis of the SVM-based model, classifying the melanoma samples against the controls.

Hình 12. Phân tích ROC của mô hình dựa trên SVM.

Một kết quả đặc biệt nữa của kỹ thuật RFE là sự "lọc chất", cụ thể được minh họa trong *Figure 8* như sau:




Figure 8. AUC values obtained by the SVM algorithm using one predictor (*MIP-1a*), two predictors (*MIP-1a* + *IL-1Ra*), three predictors (*MIP-1a* + *IL-1Ra* + *IL-7*), four predictors (*MIP-1a* + *IL-1Ra* + *IL-7* + *MIP-1b*), etc., up to six predictors.

Hình 13. Kết quả của phương pháp SVM áp dụng cho tập dữ liệu mô.

Dựa vào hình, ta nhận thấy nghiên cứu đã chọn ra được một công thức vàng chỉ gồm 4 chất: MIP-1a, MIP-1b, IL-1Ra, IL-7 với mức AUC là 0.9821, khả quan cho việc sử dụng làm xét nghiệm chẩn đoán lâm sàng. Đây chính là "Signature" mà tiêu đề bài báo nhắc đến.

2.3.4 Kiểm chứng và đánh giá mô hình

Sau khi sử dụng các phương pháp để kiểm định và xây dựng mô hình, nhóm nghiên cứu đã đi đến bước kiểm chứng và đánh giá mô hình nhằm đảm bảo kết quả khách quan và tránh hiện tượng overfitting. Cụ thể, nhóm nghiên cứu đã kiểm chứng lại bằng những phương pháp sau:

- Kiểm chứng chéo (10-fold Cross-validation): Dữ liệu được chia ngẫu nhiên thành 10 phần, mô hình được huấn luyện trên 9 phần và kiểm tra trên 1 phần còn lại. Quá trình lặp lại 10 lần để lấy kết quả trung bình.
- Kiểm chứng lại trên tập dữ liệu khác: Sử dụng bộ dữ liệu độc lập từ cơ sở dữ liệu GEPIA2 để xác nhận lại tính chính xác của các dấu ấn sinh học tìm được.
- Phân tích thành phần chính (PCA): Dùng để giảm chiều dữ liệu và trực quan hóa khả năng phân nhóm của bộ dấu ấn sinh học trên không gian 2D/3D.




Figure 9. Tissue expression according to the GEPIA2 database. An asterisk (*) indicates $p < 0.0001$.

Hình 14. Biểu hiện Mô theo bộ dữ liệu GEPIA2




Figure 10. PCA analysis on the tissue expression values of *IL-1Ra*, *IL-7*, *MIP-1a*, and *MIP-1b*.

Hình 15. Phân tích PCA cho tập dữ liệu biểu hiện mô.

2.4 Đánh giá phương pháp

Ở phần này, chúng ta sẽ cùng đánh giá các phương pháp mà nhóm tác giả đã sử dụng trong xuyên suốt quá trình nghiên cứu, bao gồm cả ưu điểm và những hạn chế. Tuy nhiên, ta sẽ tập trung vào những thiếu sót của các phương pháp trên, từ đó đưa ra những khắc phục có thể được sử dụng.

2.4.1 Ưu điểm

Bài nghiên cứu đã tìm ra được dấu ấn sinh học có tiềm năng chẩn đoán cho việc nhận biết ung thư hắc tố, đây là kết quả do nhóm tác giả đã tận dụng được những ưu điểm sau:

- *Cách tiếp cận nghiên cứu có hệ thống chặt chẽ*: Nhóm tác giả đã thực hiện nghiên cứu một cách có trình tự, từ việc phân tích các biểu hiện của Cytokines trong Huyết thanh, sau đó rút ra những nhận xét để cải thiện trong việc phân tích Mô, mọi bước nghiên cứu đều được trình bày rõ ràng, cụ thể. Đồng thời, nghiên cứu không chỉ dừng lại ở việc so sánh đơn biến mà còn mở rộng sang phân tích đa biến và phân tích mạng lưới tương quan. Điều này giúp khai thác tối đa thông tin từ dữ liệu, không bỏ sót các mối liên hệ phức tạp giữa các cytokine.
- *Sử dụng kiểm định phi tham số phù hợp*: Việc lựa chọn kiểm định Mann-Whitney và Tương quan Spearman là hoàn toàn chính xác về mặt thống kê, vì dữ liệu nồng độ cytokine trong thực tế thường bị lệch và có nhiều giá trị ngoại lai, dẫn đến giả định về phân phối chuẩn thường không thỏa, do đó không thể làm kiểm định t-test trên bộ dữ liệu kiểu này.
- *Tối ưu hóa mô hình với kiểm định chặt chẽ*: Với việc kết hợp thuật toán SVM cùng kỹ thuật chọn lọc biến đệ quy RFE, nhóm nghiên cứu đã giữ lại được tổ hợp 4 chất có tiềm năng chẩn đoán cao nhất, giúp mô hình trở nên đơn giản và tiết kiệm chi phí. Đồng thời, nhóm nghiên cứu cũng đã kiểm định lại bằng phương pháp 10-fold Cross-validation kết hợp với tập dữ liệu khác, giúp cho kết quả mô hình mang tính khách quan hơn.

2.4.2 Hạn chế

Tuy đã đạt được nhiều thành quả trong việc xây dựng mô hình chẩn đoán, bài nghiên cứu vẫn còn những hạn chế về mặt thống kê.

- *Thứ nhất*, việc **xử lý dữ liệu khuyết** còn khá thô sơ. Trong bài báo, với bộ dữ liệu huyết thanh, nhóm nghiên cứu đã xử lý dữ liệu khuyết bằng cách gán chúng bằng 0 hoặc loại bỏ hoàn toàn khỏi bộ dữ liệu. Điều này làm lệch phân phối dữ liệu thực tế và tạo ra các mối tương quan không chính xác, đây cũng có thể là nguyên nhân khiến mô hình SVM trên huyết thanh hoạt động kém hiệu quả (AUC thấp) và không ổn định.
- *Thứ hai*, **kiểm định phi tham số** còn nhiều hạn chế, dù việc kiểm định phi tham số là chính xác do tính chất của dữ liệu, tuy nhiên độ mạnh của kiểm định phi tham số sẽ thấp hơn nhiều so với kiểm định tham số như T-test hay Pearson. Điều này có thể dẫn đến làm tăng xác suất Sai lầm loại II, tức là bỏ sót những Cytokines có tiềm năng nhưng sự khác biệt chưa đủ lớn về mặt thứ hạng. (với kiểm định Mann-Whitney)
- *Thứ ba*, các giả định **ANOVA** chưa thỏa mãn hoàn toàn. Tác giả đã sử dụng ANOVA để so sánh 3 nhóm, tuy nhiên trong *table 6* được trình bày trong bài báo (bảng cũng có đính kèm trong phần trên), cột "Homogen. variances" cho thấy nhiều chất có kết quả là "N" (No), tức là phương sai không đồng nhất. Khi phương sai không đồng nhất, kết quả p-value của ANOVA truyền thống có thể không chính xác, dễ dẫn đến kết luận sai lầm về sự khác biệt giữa các nhóm.
- *Thứ tư*, sự nghi ngờ về kết quả **mô hình SVM**. Kết quả mô hình trên mô đạt $AUC = 0.99$ là một dấu hiệu cảnh báo về hiện tượng Overfitting. Mặc dù đã kiểm định lại cross-validation, nhưng mô hình có thể đã "học thuộc lòng" đặc điểm của bộ dữ liệu GENT2. Điều này dẫn đến

việc khi sử dụng mô hình cho bộ dữ liệu ở những quốc gia khác, kết quả có lẽ sẽ không còn chính xác.

Đồng thời, cũng có một vài hạn chế nhỏ cho bộ dữ liệu cũng được tác giả nhắc đến trong phần **Discussion** và **Materials and Methods**. Đầu tiên là việc các dữ liệu trong bộ dữ liệu Huyết thanh bị khuyết khá nhiều, điều này dẫn đến sự xử lý thô sơ về dữ liệu như đã nói ở trên. Tiếp theo là vấn đề về sự chênh lệch độ tuổi trong dữ liệu Huyết thanh, nhóm bệnh nhân ung thư có độ tuổi trung bình cao hơn nhóm chứng, đây là yếu tố gây nhiễu tiềm ẩn.

2.4.3 Một vài phương án khắc phục

Từ những hạn chế trong bài nghiên cứu, một vài phương án khắc phục mà nhóm tác giả có thể xem xét để thử nghiệm như sau:

- Về phần xử lý dữ liệu khuyết, thay vì chỉ gán các dữ liệu khuyết bằng 0, ta có thể sử dụng các phương pháp xử lý Data Missing cải tiến hơn như KNN Imputation (tìm các bệnh nhân có hồ sơ cytokine tương tự và lấy giá trị trung bình của họ để điền vào phần bị khuyết), hay phương pháp MICE (tạo ra nhiều bộ dữ liệu giả lập để ước lượng giá trị thiếu chính xác hơn).
- Nếu lo sợ về độ mạnh của các kiểm định phi tham số, ta có thể biến đổi bộ dữ liệu bằng phương pháp Log-transform hoặc Box-Cox transformation để đưa dữ liệu về dạng phân phối chuẩn. Nếu thành công, áp dụng T-test để tận dụng tối đa thông tin về độ lớn dữ liệu. Ngoài ra, nhóm tác giả cũng có thể tăng cỡ mẫu để bù đắp cho sự thiếu hụt công lực của kiểm định.
- Với việc giả định về tính phương sai đồng nhất của dữ liệu chưa thỏa, thay vì sử dụng ANOVA truyền thống, nên sử dụng Welch's ANOVA. Đây là phiên bản điều chỉnh của ANOVA, cho phép so sánh các nhóm có phương sai khác nhau mà vẫn đảm bảo độ tin cậy.
- Cuối cùng, hiện tượng Overfitting có thể xảy ra trong mô hình. Vì vậy, cần thực hiện thu thập mẫu dữ liệu mới từ bệnh nhân thực tế tại nhiều trung tâm khác nhau và áp dụng mô hình này để chẩn đoán, thay vì chỉ kiểm chứng trên các bộ dữ liệu có sẵn trên mạng (như GEPIA2).

Chương 3

Đề xuất câu hỏi nghiên cứu

Tiếp nối các kết quả khả quan về bộ dấu ấn sinh học chẩn đoán đã được phân tích, chương này đề xuất các hướng nghiên cứu mở rộng nhằm khai thác sâu hơn tiềm năng của bộ dữ liệu GENT2.

3.1 Phân loại Giai đoạn bằng mô hình Phi tuyến

Từ phần thảo luận của bài báo, nhóm tác giả đã thừa nhận thất bại trong việc phân biệt U nguyên phát và U di căn với chỉ số AUC khá thấp ở cột **Primary vs. Metastatic** trong *Table 9*, đây cũng chính là hạn chế lớn nhất của mô hình tuyến tính SVM. Điều này có thể do mối quan hệ giữa nồng độ cytokine và giai đoạn bệnh là phi tuyến tính và phức tạp hơn giả định của SVM.

Liệu việc áp dụng thuật toán Random Forest - một phương pháp học máy có khả năng xử lý tốt các mối quan hệ phi tuyến và tương tác giữa các biến - có giúp cải thiện độ chính xác trong chẩn đoán phân biệt giai đoạn bệnh hay không? Ta sẽ xây dựng mô hình áp dụng thuật toán trên với phương pháp như sau:

- Sử dụng dữ liệu mô (Tissue dataset) bao gồm các mẫu U nguyên phát và U di căn.
- Huấn luyện mô hình phân loại Random Forest (với 5000 cây quyết định), sau đó đánh giá mô hình bằng các chỉ số: Accuracy, Precision, Recall và F1-score.
- Cuối cùng, đánh giá xem các Cytokines nào đóng góp nhiều nhất vào quá trình phân loại bằng thuộc tính *feature_importances_*.

Ta sẽ thực hiện phương pháp trên với đoạn Code R như sau:

Trước tiên, ta sẽ cài đặt các thư viện cần thiết cho việc xây dựng mô hình.

```
1 # PHẦN 1: CÀI ĐẶT VÀ LOAD THƯ VIỆN
2 # install.packages(c("tidyverse", "caret", "randomForest", "pROC"))
3 library(tidyverse)
4 library(caret)
5 library(randomForest)
6 library(pROC)
```

Tiếp theo, ta sẽ input dữ liệu đầu vào từ file *data_GENT2_all_melanoma.csv* được lấy từ bộ dữ liệu GENT2 dùng để phân tích dữ liệu mô. Sau đó đọc và xử lý, làm sạch bộ dữ liệu trước khi bước vào xây dựng mô hình.

```
1 # PHẦN 2: ĐỌC VÀ LÀM SẠCH DỮ LIỆU (ĐÃ SỬA LỖI)
2 # =====
3
4 # 1. Đọc dữ liệu
5 df_melanoma <- read.csv("data_GENT2_all_melanoma.csv",
6   stringsAsFactors = FALSE, check.names = FALSE)
```



```

7
8 # 2. Xử lý tên cột: Xóa toàn bộ khoảng trắng thừa ở đầu và cuối
9 colnames(df_melanoma) <- trimws(colnames(df_melanoma))
10
11 # Danh sách 27 cytokine chuẩn
12 cytokine_cols <- c("IL1b", "IL-1ra (IL1rn)", "IL-2", "IL-4", "IL-5", "IL-6",
13                   "IL-7", "IL-8 (IL-8)", "IL-9", "IL-10", "IL-12(p70) (IL-12)",
14                   "IL-13", "IL-15", "IL-17", "Eotaxin", "FGF basic", "G-CSF",
15                   "GM-CSF", "IFN-g", "IP-10", "MCP-1(MCAF)", "MIP-1a (CCL3)",
16                   "MIP-1b (CCL4)", "PDGF-bb", "RANTES", "TNF-a", "VEGF (VEGFa)")
17
18 # 3. Chuẩn hóa nhãn bệnh
19 df_clean <- df_melanoma %>%
20   mutate(
21     # Chuẩn hóa về chữ thường để dễ so sánh
22     disease_lower = tolower(disease),
23
24     Target = case_when(
25       # 1. Nhóm Nguyên phát (Primary) - Ưu tiên bắt trước
26       # Bắt các từ: primary, primary (lỗi chính tả)
27       grepl("primary|priimary", disease_lower) ~ "Primary",
28
29       # 2. Nhóm Di căn (Metastatic) - MỞ RỘNG ĐỊNH NGHĨA
30       # Bắt: metastatic, metstatic, in transit (di căn quá cảnh), node (hạch),
31       # biopsy (sinh thiết - giả định là bệnh tiến triển), scalp, polypoid
32       grepl("metastatic|metstatic|biopsy", disease_lower) ~ "Metastatic",
33
34       # 3. Các trường hợp còn lại (như "melanoma" chung chung) -> Loại
35       TRUE ~ NA_character_
36     )
37   ) %>%
38   filter(!is.na(Target)) %>%
39   select(Target, all_of(cytokine_cols))
40
41 # Chuyển đổi dữ liệu
42 df_clean$Target <- as.factor(df_clean$Target)
43 df_clean[, cytokine_cols] <- lapply(df_clean[, cytokine_cols], as.numeric)
44 # Xóa khoảng trắng + dấu ngoặc mở + nội dung bên trong + dấu ngoặc đóng
45 colnames(df_clean) <- gsub("\\s*\\([\\^)]+\\)", "", colnames(df_clean))
46 colnames(df_clean) <- make.names(colnames(df_clean))
47
48 # Xử lý NA
49 df_final <- na.roughfix(df_clean)
50
51 # Kiểm tra dữ liệu sau khi làm sạch
52 table(df_final$Target)

```

Làm xong bước trên, ta sẽ có được 1 bộ dữ liệu sạch, bao gồm 1 biến phân loại *Target* chỉ Nguyên phát (Primary) hoặc Di căn (Metastatic) và 27 biến số tương ứng với từng loại Cytokines. Số lượng cụ thể như sau:

```
##
## Metastatic      Primary
##              181      83
```

Hình 16.

Chú ý là trong bài nghiên cứu, số lượng bệnh nhân Metastatic là tận 227, tuy nhiên ta không biết nhóm nghiên cứu đã chọn lọc bệnh nhân dựa trên những yếu tố nào, nên ta sẽ chỉ lọc ra những bệnh nhân có trạng thái rõ ràng *disease* trong file dữ liệu là *melanoma metastatic* và *melanoma biopsy* để đảm bảo sự chính xác về mặt y học.

Tiếp theo, ta sẽ chia bộ dữ liệu ra thành 2 phần: Train và Test, sau đó huấn luyện bộ dữ liệu trên tập Train cho mô hình Random Forest như sau:

```
1  # PHẦN 3: HUẤN LUYỆN MÔ HÌNH RANDOM FOREST
2  # =====
3
4  set.seed(123) # Để kết quả lặp lại được
5
6  # 1. Chia dữ liệu Train (70%) - Test (30%)
7  trainIndex <- createDataPartition(df_final$Target, p = .7,
8                                   list = FALSE,
9                                   times = 1)
10 data_train <- df_final[ trainIndex,]
11 data_test  <- df_final[-trainIndex,]
12
13 # 2. Xây dựng mô hình Random Forest
14 # ntree = 500: Số lượng cây quyết định
15 # mtry: Số lượng biến được chọn ngẫu nhiên tại mỗi nút (mặc định là sqrt(số biến))
16 rf_model <- randomForest(Target ~ .,
17                           data = data_train,
18                           ntree = 5000,
19                           importance = TRUE)
20
21 # Xem tóm tắt mô hình
22 print(rf_model)
```

Ta được kết quả như sau:

```
##
## Call:
## randomForest(formula = Target ~ ., data = data_train, ntree = 5000,      importance =
##               Type of random forest: classification
##               Number of trees: 5000
## No. of variables tried at each split: 5
##
## OOB estimate of error rate: 19.35%
## Confusion matrix:
##           Metastatic Primary class.error
## Metastatic      120       7 0.05511811
## Primary         29      30 0.49152542
```

Hình 17.

Từ kết quả mô hình, ta thấy chỉ số OOB estimate of error rate là 19.35%, tức là độ chính xác tổng thể (Accuracy) = $100\% - 19.35\% = 80.65\%$, con số này cao hơn nhiều so với kết quả của thuật toán SVM tuyến tính trong bài báo gốc (thường chỉ đạt 60% khi phân biệt giai đoạn).


Đồng thời, ta cũng phân tích kết quả thấy được từ Ma trận nhầm lẫn (Confusion matrix):

- Với Nhóm *Metastatic*, mô hình dự đoán đúng 120/127 mẫu, sai số (class.error) chỉ khoảng $0.055 \approx 5.5\%$, điều này chứng tỏ mô hình hoạt động xuất sắc với nhóm Di căn. Độ nhạy (Sensitivity) đạt tới 94.5%. Nghĩa là nếu bệnh nhân đã di căn, mô hình gần như chắc chắn sẽ phát hiện ra.
- Tuy nhiên, với Nhóm *Primary*, mô hình chỉ dự đoán đúng 30/59 mẫu, sai số khoảng 50%. Chứng tỏ mô hình hoạt động kém với nhóm Nguyên phát. Vấn đề này có thể do cỡ mẫu, vì số lượng mẫu của nhóm *Metastatic* gấp đôi nhóm *Primary*, dẫn đến việc mô hình có thể ưu tiên nhóm *Metastatic* hơn.

Tiếp theo, ta sẽ đánh giá mô hình trên tập Test như sau:

```
1 # PHẦN 4: ĐÁNH GIÁ MÔ HÌNH TRÊN TẬP TEST
2 # =====
3 # 1. Dự báo
4 pred_class <- predict(rf_model, data_test, type = "class") # Dự báo nhãn
5 pred_prob  <- predict(rf_model, data_test, type = "prob")  # Dự báo xác suất
6
7 # 2. Ma trận nhầm lẫn (Confusion Matrix) & Độ chính xác
8 conf_matrix <- confusionMatrix(pred_class, data_test$Target, mode = "everything")
9
10 # 3. Vẽ đường cong ROC và tính AUC
11 roc_obj <- roc(data_test$Target, pred_prob[, "Metastatic"], levels = c("Primary", "Metastatic"))
12 auc_value <- auc(roc_obj)
13 plot(roc_obj, main = paste("ROC Curve (AUC =", round(auc_value, 3), ")"), col = "blue")
```

Ta thu được kết quả như sau:




Hình 18. Đường cong ROC và chỉ số AUC

Với chỉ số $AUC = 0.838$, mô hình đã cải thiện rất nhiều so với các chỉ số AUC trong *Table 9* ở cột Primary vs. Metastatic trong bài báo cáo (chỉ từ khoảng 0.5 đến 0.6). Hơn nữa, ta còn có thể trích xuất ra những chất quan trọng trong việc phân biệt Primary vs. Metastatic như sau:

```

1  # PHẦN 5: TẦM QUAN TRỌNG CỦA CÁC BIẾN (FEATURE IMPORTANCE)
2  # =====
3
4  # 1. Trích xuất độ quan trọng
5  importance_df <- as.data.frame(importance(rf_model))
6  importance_df$Feature <- rownames(importance_df)
7
8  # 2. Sắp xếp và vẽ biểu đồ Top 10 cytokine quan trọng nhất
9  top_features <- importance_df %>%
10     arrange(desc(MeanDecreaseGini)) %>% # Sắp xếp giảm dần theo chỉ số Gini
11     head(10)
12
13  ggplot(top_features, aes(x = reorder(Feature, MeanDecreaseGini), y = MeanDecreaseGini)) +
14     geom_bar(stat = "identity", fill = "steelblue") +
15     coord_flip() + # Xoay ngang biểu đồ
16     labs(title = "Top 10 Cytokine quan trọng nhất phân biệt Primary vs Metastatic",
17          x = "Cytokine",
18          y = "Mức độ quan trọng (Mean Decrease Gini)") +
19     theme_minimal()

```



Hình 19.

Từ hình ảnh trên, ta thấy được những chất quan trọng đặc biệt có tiềm năng chẩn đoán giữa giai đoạn U nguyên phát và U di căn, từ đây, các nhà nghiên cứu y học có thể phân tích và tìm hiểu lý do, từ đó xây dựng các nghiên cứu khác liên quan đến tổ hợp các chất này.

3.2 Phân loại Giai đoạn dựa trên tổ hợp 4 gen "chữ ký"

Dựa trên dữ liệu *data_GENT2_all_melanoma.csv* mà ta có, cột disease phân loại rất chi tiết các trạng thái bệnh. Tuy nhiên, bài báo gốc tập trung chủ yếu vào việc phân biệt giữa "Có bệnh" và "Không bệnh". Và nhờ vào những nhiên cứu đó, ta cũng biết được tổ hợp 4 gen "chữ ký" có khả năng chẩn đoán tốt là: IL-1Ra, IL-7, MIP-1a, MIP-1b. Nhưng liệu tổ hợp 4 gen này có khả năng phân loại giai đoạn Ung thư nguyên phát và Ung thư di căn không? Như vậy, ta thử đặt ra câu hỏi: **Liệu biểu hiện của bộ 4 gen "chữ ký" có sự khác biệt đáng kể giữa nhóm Ung thư nguyên phát và Ung thư di căn không?**

Ta sẽ thử kiểm tra qua đoạn code sau:

```

1 library(ggplot2)
2 library(dplyr)
3 library(tidyr)
4
5 # 1. Đọc dữ liệu
6 # check.names = FALSE để giữ nguyên tên cột gốc (có khoảng trắng, ký tự đặc biệt)
7 df <- read.csv("data_GENT2_all_melanoma.csv", check.names = FALSE, stringsAsFactors = FALSE)
8
9 # 2. Xử lý dữ liệu: Phân loại Primary và Metastatic
10 # Cột 'disease' chứa các tên như "melanoma primary", "melanoma metastatic", v.v.
11 df_clean <- df %>%
12   mutate(
13     Stage = case_when(
14       grepl("primary|priimary", disease, ignore.case = TRUE) ~ "Primary",
15       grepl("metastatic|metstastic|biopsy", disease, ignore.case = TRUE) ~ "Metastatic",
16       TRUE ~ "Other" # Các trường hợp không rõ

```

```

17   )
18   ) %>%
19   filter(Stage %in% c("Primary", "Metastatic")) # Chỉ lấy 2 nhóm cần so sánh
20
21   # In số lượng mẫu mỗi nhóm để kiểm tra
22   print(table(df_clean$Stage))
23
24   # 3. Đổi tên cột gen cho dễ xử lý (Tên gốc trong CSV khá dài và có dấu cách)
25   # 'IL-1ra (IL1rn)', 'IL-7 ', 'MIP-1a (CCL3)', 'MIP-1b (CCL4)'
26   df_analysis <- df_clean %>%
27     rename(
28       # Cấu trúc: Tên_Mới = `Tên_Cũ_Trong_Data`
29       # Lưu ý: Dùng dấu huyền (backtick) `` để bao quanh tên có ký tự đặc biệt
30
31       IL1Ra = `IL-1ra (IL1rn)`,
32       IL7 = `IL-7`, # Khả năng cao là tên này (không có dấu cách)
33       # IL7 = `IL.7`,
34
35       MIP1a = `MIP-1a (CCL3)`,
36       MIP1b = `MIP-1b (CCL4)`
37     ) %>%
38     select(Stage, IL1Ra, IL7, MIP1a, MIP1b)
39
40   # 5. Chuyển dữ liệu sang dạng dài (Long format) để vẽ đồ thị
41   df_long <- df_analysis %>%
42     pivot_longer(cols = c(IL1Ra, IL7, MIP1a, MIP1b),
43                 names_to = "Gene",
44                 values_to = "Expression")
45
46   # 6. Vẽ biểu đồ Boxplot so sánh
47   ggplot(df_long, aes(x = Stage, y = Expression, fill = Stage)) +
48     geom_boxplot(outlier.shape = NA, alpha = 0.7) +
49     geom_jitter(width = 0.2, alpha = 0.2, size = 1) + # Hiện các điểm dữ liệu mờ
50     facet_wrap(~Gene, scales = "free_y") + # Chia thành 4 biểu đồ con
51     theme_bw() +
52     labs(
53       title = "So sánh biểu hiện 4 gen chỉ dấu: Nguyên phát (Primary) vs Di căn (Metastatic)",
54       y = "Mức độ biểu hiện (Expression Level)",
55       x = "Giai đoạn bệnh"
56     ) +
57     scale_fill_manual(values = c("Primary" = "#00AFBB", "Metastatic" = "#E7B800"))
58
59   # 7. Thực hiện kiểm định thống kê Mann-Whitney U (Wilcoxon rank-sum test)
60   target_genes <- c("IL1Ra", "IL7", "MIP1a", "MIP1b")
61
62   print("--- KẾT QUẢ KIỂM ĐỊNH MANN-WHITNEY ---")
63   for (gene in target_genes) {
64     # Tách dữ liệu
65     group_primary <- df_analysis[df_analysis$Stage == "Primary", gene]
66     group_metastatic <- df_analysis[df_analysis$Stage == "Metastatic", gene]
67
68     # Kiểm định

```


```

69 test_result <- wilcox.test(group_primary, group_metastatic)
70
71 # In kết quả
72 cat(paste0("\nGen: ", gene, "\n"))
73 cat(paste("P-value:", format.pval(test_result$p.value, digits = 4), "\n"))
74 if(test_result$p.value < 0.05) {
75     cat("-> Có sự khác biệt ý nghĩa thống kê.\n")
76 } else {
77     cat("-> Không có sự khác biệt ý nghĩa thống kê.\n")
78 }
79 }

```

Việc xử lý dữ liệu đầu vào căn bản giống như mục 3.1, ở đây ta sẽ dùng các kiểm định Mann - Whitney và biểu đồ boxplot để so sánh biểu hiện gen trong Mô giữa nhóm Primary và nhóm Metastatic. Kết quả thu được như sau:

So sánh bi.u hi.n 4 gen ch. d.u: Nguyên phát (Primary) vs Di căn (Metastatic)



Hình 20. Biểu đồ boxplot biểu hiện tổ hợp 4 chất trong Mô giữa Nhóm Primary và Metastatic

Từ biểu đồ trên, ta thấy chất IL1Ra không có sự khác biệt quá lớn giữa 2 nhóm, trong khi cả 3 chất còn lại đều có biểu hiện nồng độ các chất trong Mô bé hơn ở nhóm Primary so với Metastatic. Thật vậy, với kiểm định Mann - Whitney ta có kết quả như sau:

```
##
## Gen: IL1Ra
## P-value: 0.9972
## -> Không có sự khác biệt ý nghĩa thống kê.
##
## Gen: IL7
## P-value: 0.0204
## -> Có sự khác biệt ý nghĩa thống kê.
##
## Gen: MIP1a
## P-value: 0.007718
## -> Có sự khác biệt ý nghĩa thống kê.
##
## Gen: MIP1b
## P-value: 0.01285
## -> Có sự khác biệt ý nghĩa thống kê.
```

Hình 21. Biểu đồ boxplot biểu hiện tổ hợp 4 chất trong Mô giữa Nhóm Primary và Metastatic

Dựa vào các giá trị p-value, với mức ý nghĩa 0.05, ta kết luận không có sự khác biệt về biểu hiện gen IL1Ra giữa 2 nhóm, nhưng với 3 chất còn lại thì có sự khác biệt mang ý nghĩa thống kê.

Từ đó, các nhóm tác giả có thể phân tích thêm về 3 chất trên, hoặc tiếp tục sử dụng kiểm định Mann - Whitney để tìm hiểu về ảnh hưởng của các Cytokines còn lại dựa vào tính chất và đặc điểm sinh học.

Chương 4

Mô phỏng lại các phân tích thống kê

Trong chương này, ta sẽ chạy và mô phỏng lại những phân tích thống kê mà bài báo đã sử dụng. Vì bộ dữ liệu huyết thanh (Serum Data) không được công khai, nên ta chỉ chạy lại các thống kê trên bộ dữ liệu Mô (Tissue Data) được lấy từ cơ sở dữ liệu GENT2. Cụ thể, ta sẽ chạy kiểm định Mann - Whitney lại cho bộ dữ liệu giữa nhóm Normal và nhóm Melanoma, sau đó xây dựng mô hình SVM và đánh giá, cuối cùng là tính toán các giá trị AUC và vẽ biểu đồ ROC để xem chất nào có tiềm năng chẩn đoán. Cụ thể như sau:

```
1 library(tidyverse)
2 library(caret)
3 library(pROC)
4 library(randomForest)
5 library(e1071)
6
7 # 1. Đọc lại dữ liệu gốc
8 df_normal <- read.csv("data_GENT2_normal.csv", stringsAsFactors = FALSE, check.names = FALSE)
9 colnames(df_normal) <- make.names(gsub("\\s*\\([~]\\+\\)", "", trimws(colnames(df_normal))))
10 df_normal$Group <- "Normal"
11
12 df_melanoma <- read.csv("data_GENT2_all_melanoma.csv",
13 stringsAsFactors = FALSE, check.names = FALSE)
14 colnames(df_melanoma) <- make.names(gsub("\\s*\\([~]\\+\\)", "", trimws(colnames(df_melanoma))))
15 df_melanoma$Group <- "Melanoma"
16
17 # 2. Xác định cột Cytokine chuẩn (LOẠI BỎ GROUP RA KHỎI DANH SÁCH NÀY)
18 common_cols <- intersect(colnames(df_normal), colnames(df_melanoma))
19
20 # Danh sách các cột KHÔNG PHẢI là cytokine (Thêm "Group" vào đây)
21 meta_cols_remove <- c("Group", "ID", "Dataset_ID", "Sample_ID", "disease", "Tissue",
22 "Index", "progressive.number", "Expression_level",
23 "gender", "SRY", "MSL3", "ESR1", "ESR2", "PGR", "AR")
24
25 # Chỉ lấy tên các chất cytokine
26 cytokine_cols <- setdiff(common_cols, meta_cols_remove)
27
28 # 3. Gộp dữ liệu (Giữ lại cột Group và Cytokine)
29 df_combined <- bind_rows(
30 df_normal %>% select(Group, all_of(cytokine_cols)),
31 df_melanoma %>% select(Group, all_of(cytokine_cols))
32 )
33
34 # 4. Chuyển đổi dữ liệu (CHỈ chuyển cytokine sang số, KHÔNG dùng đến Group)
35 df_combined[, cytokine_cols] <- lapply(df_combined[, cytokine_cols], as.numeric)
```

```

36 df_combined$Group <- as.factor(df_combined$Group)
37
38 # 5. Xử lý NA
39 df_combined <- na.roughfix(df_combined)
40
41 # Kiểm tra lại xem cột Group còn sống không?
42 print(table(df_combined$Group))
43 # =====
44 # PHẦN KIỂM ĐỊNH MANN-WHITNEY
45
46 results <- data.frame(Cytokine = character(),
47                       Median_Normal = numeric(),
48                       Median_Melanoma = numeric(),
49                       P_Value = numeric(),
50                       stringsAsFactors = FALSE)
51
52 for (cyto in cytokine_cols) {
53   if (is.null(df_combined[[cyto]])) next
54
55   test_res <- wilcox.test(df_combined[[cyto]] ~ df_combined$Group, exact = FALSE)
56   results <- rbind(results, data.frame(Cytokine = cyto,
57                                       Median_Normal = median(df_combined[df_combined$Group == "Normal", cyto]),
58                                       Median_Melanoma = median(df_combined[df_combined$Group == "Melanoma", cyto]),
59                                       P_Value = test_res$p.value))
60 }
61 results$Adj_P_Value <- p.adjust(results$P_Value, method = "bonferroni")
62 results_sorted <- results %>% arrange(Adj_P_Value)
63 print("--- KẾT QUẢ REPLICATION (TOP 10) ---")
64 print(head(results_sorted, 10))
65
66 # =====
67 # TÁI LẬP MÔ HÌNH MÁY HỌC SVM (SUPPORT VECTOR MACHINE)
68
69 set.seed(123)
70
71 # 1. Chia dữ liệu Train (70%) - Test (30%)
72 trainIndex <- createDataPartition(df_combined$Group, p = 0.7, list = FALSE)
73 data_train <- df_combined[trainIndex, ]
74 data_test <- df_combined[-trainIndex, ]
75
76 # 2. Huấn luyện mô hình SVM
77 # Chúng ta thử Radial (phổ biến cho dữ liệu sinh học)
78 svm_model <- svm(Group ~ ., data = data_train, kernel = "linear", probability = TRUE)
79
80 # 3. Dự báo trên tập Test
81 pred_class <- predict(svm_model, data_test)
82 pred_prob <- predict(svm_model, data_test, probability = TRUE) # Để tính AUC nếu cần
83
84 # 4. Đánh giá kết quả (Confusion Matrix)
85 conf_matrix <- confusionMatrix(pred_class, data_test$Group)
86
87 print("--- KẾT QUẢ MÔ HÌNH SVM (Tái lập) ---")

```

```

88 print(conf_matrix)
89
90 # Trích xuất các chỉ số quan trọng để so sánh với bài báo
91 accuracy <- conf_matrix$overall['Accuracy']
92 sensitivity <- conf_matrix$byClass['Sensitivity'] # Khả năng phát hiện Melanoma
93 specificity <- conf_matrix$byClass['Specificity'] # Khả năng phát hiện Normal
94
95 print(paste("Độ chính xác (Accuracy):", round(accuracy * 100, 2), "%"))

```

Ta được các kết quả liên quan đến kiểm định Mann - Whitney và chỉ số mô hình SVM như trong bài báo là:

```
## [1] "--- KẾT QUẢ REPLICATION (TOP 10) ---"
```

```
print(head(results_sorted, 10))
```

##	Cytokine	Median_Normal	Median_Melanoma	P_Value	Adj_P_Value
## 1	MIP.1a	5.087463	8.011228	3.412382e-63	9.213431e-62
## 2	IL.1ra	9.381543	6.851736	3.204521e-55	8.652207e-54
## 3	IL.7	7.266787	5.392317	6.278743e-50	1.695261e-48
## 4	MIP.1b	5.169925	7.807355	3.928552e-48	1.060709e-46
## 5	IL.12	4.247928	2.321928	8.266624e-29	2.231989e-27
## 6	TNF.a	6.087463	7.467606	3.655691e-22	9.870366e-21
## 7	RANTES	6.845490	7.991185	4.262960e-20	1.150999e-18
## 8	IL.10	3.700440	4.906890	2.738912e-13	7.395062e-12
## 9	IFN.g	4.700440	5.491853	2.199391e-12	5.938356e-11
## 10	IL.6	5.584962	6.339850	8.427882e-09	2.275528e-07

Hình 22. Bảng trung vị và kết quả kiểm định Mann - Whitney của từng chất cho 2 nhóm

```
## [1] "--- KẾT QUẢ MÔ HÌNH SVM (Tái lập) ---"
```

```
print(conf_matrix)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction Melanoma Normal
##   Melanoma      99      2
##   Normal        6      61
##
##           Accuracy : 0.9524
##           95% CI : (0.9083, 0.9792)
##   No Information Rate : 0.625
##   P-Value [Acc > NIR] : <2e-16
##
##           Kappa : 0.8997
##
##   Mcnemar's Test P-Value : 0.2888
##
##           Sensitivity : 0.9429
##           Specificity : 0.9683
##           Pos Pred Value : 0.9802
##           Neg Pred Value : 0.9104
##           Prevalence : 0.6250
##           Detection Rate : 0.5893
##           Detection Prevalence : 0.6012
##           Balanced Accuracy : 0.9556
##
##           'Positive' Class : Melanoma
##
```

Hình 23. Kết quả mô hình SVM

Ta thấy kết quả sẽ khác trong báo cáo vì dữ liệu lấy từ database GENT2 đã được nhóm nghiên cứu lọc thủ công dựa vào các yếu tố sinh học nào đó (không được trình bày trong báo cáo), còn đoạn code trên lấy toàn bộ dữ liệu trong bộ dữ liệu trên.

Tiếp theo, ta tính toán các giá trị AUC và mô phỏng lại hình ảnh đường cong ROC như sau:

```
1  # PHẦN 2: TÍNH TOÁN AUC VÀ CHỌN TOP MARKER
2
3  auc_results <- data.frame(Cytokine = character(), AUC = numeric(), stringsAsFactors = FALSE)
4
5  for (cyto in cytokine_cols) {
6    # Tính đường cong ROC
7    roc_obj <- roc(df_combined$Group, df_combined[[cyto]],
8                  levels = c("Normal", "Melanoma"),
9                  direction = "<", quiet = TRUE)
10
11    # Lưu giá trị AUC
12    auc_results <- rbind(auc_results, data.frame(Cytokine = cyto, AUC = as.numeric(roc_obj$auc)))
13  }
14
15  # Sắp xếp giảm dần theo AUC (Cao nhất nằm trên cùng)
16  auc_results <- auc_results %>% arrange(desc(AUC))
```

```

17
18 top_cytokines <- head(auc_results, 4) # Lấy 4 chất tốt nhất
19 print("--- TOP CYTOKINES CÓ AUC CAO NHẤT ---")
20 print(top_cytokines)
21
22 # =====
23 # PHẦN 3: VẼ BIỂU ĐỒ ROC (FIGURE 4)
24
25 # Tạo danh sách các đối tượng ROC để vẽ gộp
26 roc_list <- list()
27 for (cyto in top_cytokines$Cytokine) {
28   roc_obj <- roc(df_combined$Group, df_combined[[cyto]],
29                 levels = c("Normal", "Melanoma"),
30                 direction = "<", quiet = TRUE)
31
32   # Tạo nhãn hiển thị tên + giá trị AUC (Ví dụ: IL-6 (AUC = 0.95))
33   label <- paste0(cyto, " (AUC = ", round(roc_obj$auc, 2), ")")
34   roc_list[[label]] <- roc_obj
35 }
36
37 # Vẽ biểu đồ bằng ggroc (giao diện đẹp của ggplot2)
38 ggroc(roc_list, legacy.axes = TRUE) + # legacy.axes=TRUE để trục hoành là 1-Specificity
39   geom_abline(intercept = 0, slope = 1, color = "grey", linetype = "dashed") +
40   theme_minimal() +
41   labs(title = "Figure 4: Biểu đồ ROC đánh giá khả năng chẩn đoán Melanoma",
42        x = "1 - Độ đặc hiệu (False Positive Rate)",
43        y = "Độ nhạy (Sensitivity)",
44        color = "Cytokine") +
45   theme(legend.position = "bottom",
46         plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
47         legend.text = element_text(size = 10)) +
48   scale_color_brewer(palette = "Dark2")

```


Ta có kết quả như sau:

```
## [1] "--- TOP CYTOKINES CÓ AUC CAO NHẤT ---"
```

```
print(top_cytokines)
```

```
##   Cytokine      AUC
## 1  MIP.1a 0.9225660
## 2  MIP.1b 0.8670887
## 3   TNF.a 0.7437779
## 4  RANTES 0.7312119
```

Hình 24. Top 4 Cytokines có AUC cao nhất



Hình 25. Biểu đồ ROC của 4 Cytokines trên

Chương 5

Tổng kết

Theo nhóm nghiên cứu, đây là lần đầu tiên nhóm báo cáo về sự khác biệt đáng kể trong biểu hiện của cytokine được xem như một chức năng của trạng thái bệnh lý, bên cạnh các yếu tố lâm sàng như giới tính, tuổi tác hoặc độ dày Breslow, tất cả được đều được phân tích trong dữ liệu về biểu hiện huyết thanh của một tập dữ liệu bệnh nhân lớn. Hơn nữa, bằng cách phân tích biểu hiện gen trong một tập dữ liệu biểu hiện mô lớn, nhóm cũng báo cáo một dấu hiệu 4 gen có tính liên quan tương đối cao giúp phân biệt các đối chứng với bệnh nhân u ác tính, đóng góp lớn trong việc chẩn đoán.

Thật vậy, các kiểm định Mann - Whitney, ANOVA, các thuật toán học máy như SVM và phương pháp RFE cùng với nhiều những kiểm định và phương pháp thống kê đã được sử dụng xuyên suốt bài nghiên cứu. Những kết quả và phân tích thống kê này đã khẳng định và củng cố thêm những đánh giá, suy luận của nhóm nghiên cứu trong việc điều tra biểu hiện của các Cytokines/Chemokine trong Huyết thanh và Mô. Cuối cùng, nhóm đã đạt được những kết quả nghiên cứu đáng chú ý, có tiềm năng để phát triển thêm những đề tài nghiên cứu Y/Sinh học khác dựa vào Thống kê suy luận.

Tài liệu tham khảo

- [Can23] Cancer Research UK. Breslow thickness, 2023. Truy cập ngày 29/01/2026.
- [Chand] Charlesworth Author Services. Significance and use of post-hoc analysis studies, n.d. Truy cập ngày 29/01/2026.
- [Ken24] Will Kenton. Analysis of variance (ANOVA). Investopedia, 2024. Truy cập ngày 29/01/2026.
- [Laend] Laerd Statistics. Spearman’s rank-order correlation, n.d. Truy cập ngày 29/01/2026.
- [Mel24] Melanoma Institute Australia. What is melanoma?, 2024. Truy cập ngày 29/01/2026.
- [Quand] QuantHub. How to read a correlation heatmap, n.d. Truy cập ngày 29/01/2026.
- [Thend] Thermo Fisher Scientific. Chemokines and cytokines, n.d. Truy cập ngày 29/01/2026.
- [WLHS14] David Weinstein, John Leininger, Carl Hamby, and Bijan Safai. Diagnostic and prognostic biomarkers in melanoma. *The Journal of Clinical and Aesthetic Dermatology*, 7(6):13–24, 2014.